Dr. Rob van Eijk
Managing Director for Europe, Future of Privacy Forum

Transparantie expertsystemen. Onderbouwen van redenering?

18 maart 2021
Leiden Legal Technologies Program
Leiden Centre of Data Science & Centre for Professional Learning

Universiteit Leiden
Leiden Centre of Data Science

FUTURE OF PRIVACY FORUM

© 2021, R. van Eijk, BY-NC-SA

Future of Privacy Forum

The Supporters

175+	40+	20+	5
Companies	Leading Academics	Advocates and Civil Society	Foundations

The Mission

Privacy leadership and scholarship, advancing principled data practices in support of emerging technologies.
Developing privacy protections, ethical norms, and workable business practices.

The Workstreams

Youth & Education	Ad Tech	Ethics	Global Privacy
Artificial Intelligence	Biometrics	De-identification	Policymaker Education
Mobility Technologies	Smart Communities	Health	AR/VR

Recap: regelgebaseerde systemen

- Een reeks instructies die door een computer kan worden toegepast.
- Bijvoorbeeld: een als-dan regel

```
If age > 25 then predict favorite sport = tennis
```

- Met algoritmen kunnen we – stap voor stap - complexe problemen oplossen.
- Een consistent formeel systeem gebaseerd op logica.

URL: https://corels.eecs.harvard.edu/corels/whatarerulelists.html.

© 2021, R. van Eijk, BY-NC-SA

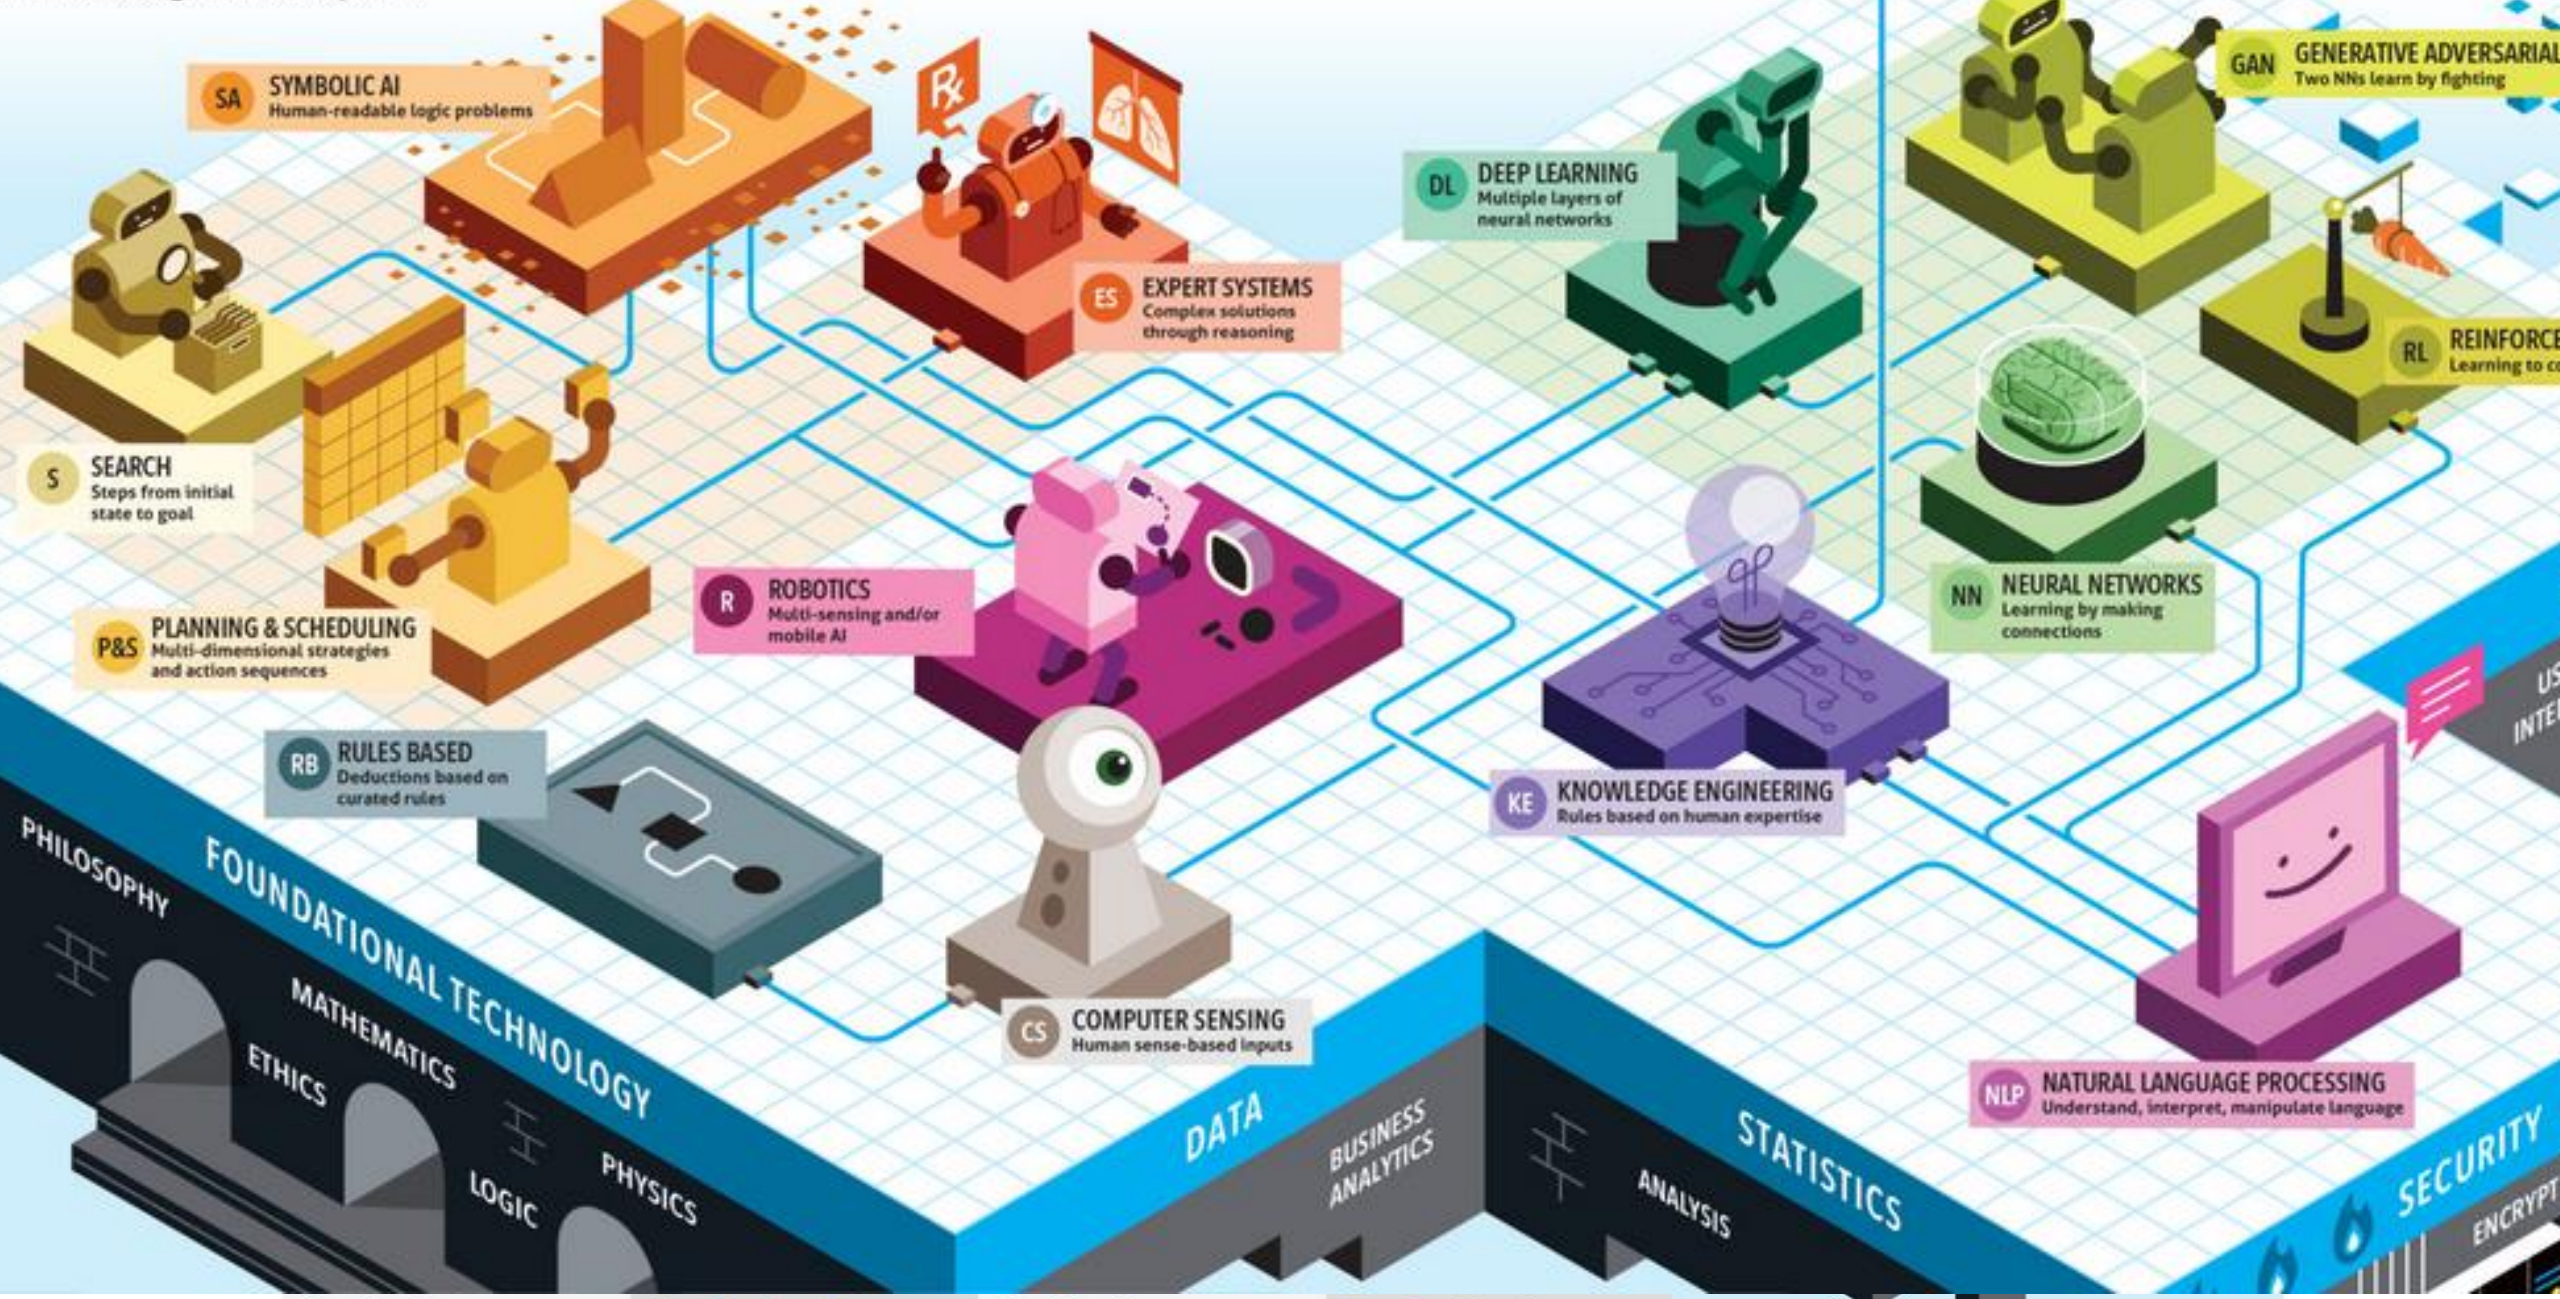

URL: https://fpf.org/blog/the-spectrum-of-artificial-intelligence-an-infographic-tool/.

© 2021, R. van Eijk, BY-NC-SA

Hoe werkt dit systeem met regels? (1)

home | loket | ontheffing speed-pedelec

Ontheffing speed-pedelec

Bestuurders van speed-pedelecs met een ontheffing kunnen vanaf 1 april 2020 ook gebruik maken van het fietspad.

De speed-pedelec is een snelle elektrische fiets die bij snelheden tot 45 km/u elektrisch wordt ondersteund.
Om de gebruikers van speed-pedelecs veilig door de stad te laten fietsen, mogen ze per 1 april 2020 zelf beslissen waar ze willen fietsen: op de rijbaan óf op het fietspad. Om op het fietspad te mogen fietsen, moeten ze in het bezit zijn van een ontheffing.

Online

Vraag de ontheffing online aan via de knop 'ontheffing aanvragen'.

Ontheffing aanvragen

URL: https://www.rotterdam.nl/loket/ontheffing-speed-pedelec/.

© 2021, R. van Eijk, BY-NC-SA

Hoe werkt dit systeem met regels? (1)

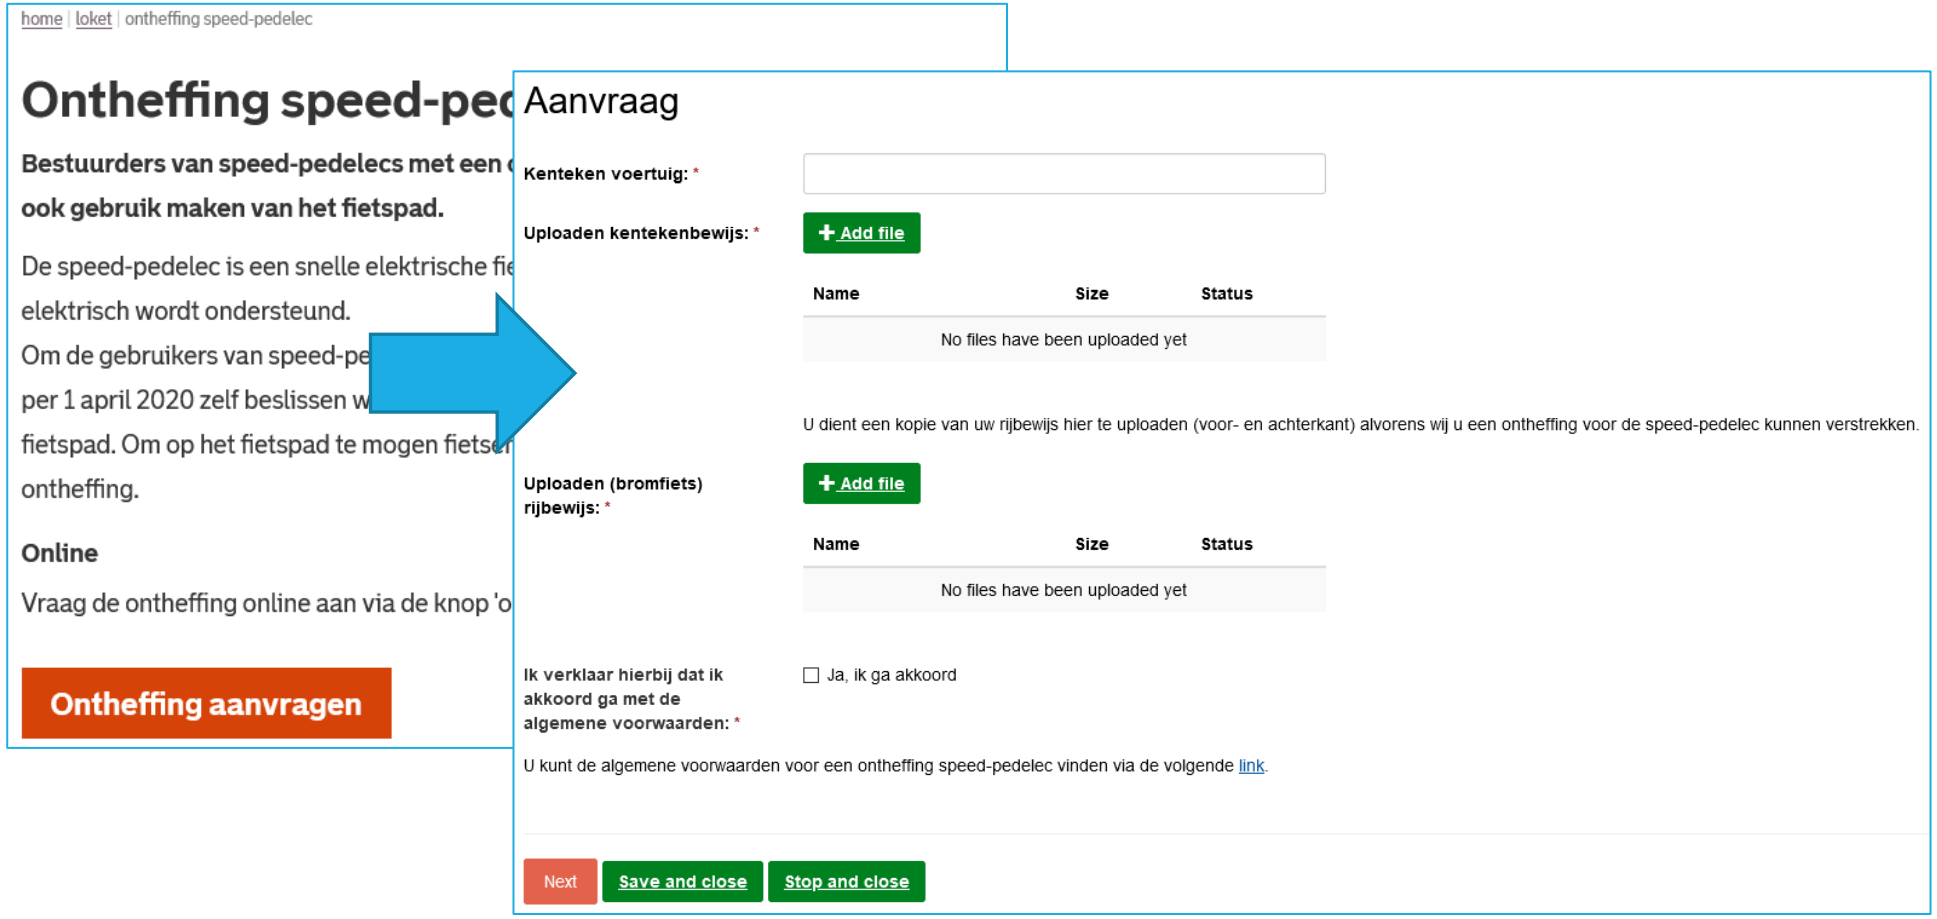

URL: https://www.rotterdam.nl/loket/ontheffing-speed-pedelec/.

© 2021, R. van Eijk, BY-NC-SA

Hoe werkt dit systeem met regels? (1)

home | loket | ontheffing speed-pedelec

Ontheffing speed-pe

Bestuurders van speed-pedelecs met een
ook gebruik maken van het fietspad.

De speed-pedelec is een snelle elektrische fie
elektrisch wordt ondersteund.
Om de gebruikers van speed-pe
per 1 april 2020 zelf beslissen w
fietspad. Om op het fietspad te mogen fietse
ontheffing.

Online

Vraag de ontheffing online aan via de knop 'o

Ontheffing aanvragen

Aanvraag

Kenteken voertuig: *

Uploaden kentekenbewijs: * + Add file

Name	Size	Status
No files have been uploaded yet		

Uploaden (bromfiets) rijbewijs: *

Ik verkla
akkoord
algemene voorwaarde

U kunt de algemene voorwaa

Next | Save and close

To 'rob@blaeu.com'

Van Eijk - ontheffing speed-pedelec.pdf
36 KB

Geachte meneer Van Eijk,

Onlangs heeft u bij de gemeente Rotterdam een aanvraag ingediend voor het verlenen van de ontheffing "Speed-Pedelec op verplicht en onverplicht fietspad" in Rotterdam.

Naar aanleiding van uw aanvraag deel ik u mede dat uw aanvraag is gehonoreerd, want het voldoet aan de gestelde eisen ten aanzien van het voertuigtype (speed-pedelec) en rijbewijsbezit of bromfietsrijbewijsbezit. Daarom is het besluit genomen uw aanvraag voor een ontheffing te verlenen. In de bijlage kunt u deze vinden.

Ik verwacht u hiermee voldoende te hebben geïnformeerd. Indien u nog vragen heeft dan kunt u reageren via een reply op deze e-mail.

Met vriendelijke groet,

URL: https://www.rotterdam.nl/loket/ontheffing-speed-pedelec/.

© 2021, R. van Eijk, BY-NC-SA

Hoe werkt dit systeem met regels? (2)

BESLUIT:

Namens het college van Burgemeester en Wethouders van Rotterdam,

- Te bepalen dat deze ontheffing uitsluitend gebruikt mag worden door RJ van Eijk, als bestuurder van de speed-pedelec met het kenteken [redacted]
- Te bepalen dat van deze ontheffing uitsluitend gebruik gemaakt mag worden op alle verplichte fietspaden (G11) en onverplichte fietspaden (G13) binnen de bebouwde kom van de gemeente Rotterdam;
- Te bepalen dat de overige wettelijke verplichtingen voor de speed-pedelec, zoals de gele bromfietskentekenplaat, de eis dat de bestuurder minimaal 16 jaar is en een bromfietsrijbewijs heeft en de helmplicht onverkort gelden;
- Bij gebruikmaking van de ontheffing dient:
  - De ontheffing of een kopie daarvan, waaronder mede wordt begrepen een afbeelding op een smartphone, laptop, tablet of ander mobiel digitaal apparaat of toestel kunnen worden getoond aan de handhaver.
  - De bestuurder instructies en aanwijzingen van de Politie, danwel Stadsbeheer/Toezicht & Handhaving stipt en onmiddellijk op te volgen;
- De bestuurder van de speed-pedelec mag het overige verkeer niet in gevaar brengen;
- De bestuurder van de speed-pedelec dient het verzoorzaken van hinder aan het overige fietsverkeer te allen tijde zoveel mogelijk te beperken en daarbij in acht te nemen op het fietspad als gast toegestaan te zijn;
- De bestuurder van de speed-pedelec mag op het verplichte fietspad (G11) en het onverplichte fietspad (G13) niet harder rijden dan 30 km/h;
- Schades, welke voortvloeien uit het gebruik van deze ontheffing, zijn geheel voor risico van de ontheffingshouder;
- Bij het niet voldoen aan de voorwaarden van deze ontheffing wordt de aanvrager geacht te hebben gehandeld zonder ontheffing;
- Het niet naleven van de voorwaarden kan leiden tot onmiddellijke intrekking van de ontheffing;
- De ontheffing vervalt van rechtswege per 31 maart 2022;

© 2021, R. van Eijk, BY-NC-SA

Onderbouwen van redenering?

- Een systeem gebaseerd op regels;
- Hoe leg je uit hoe dat werkt?
- Hoe onderbouw je de werking van het systeem?
- Hoe zorg je ervoor dat je *transparant* bent over de de regels waarop het systeem gebaseerd is?

© 2021, R. van Eijk, BY-NC-SA

Transparantie? Uitlegbaar? Compleet?

- Als de aanvrager inlogt met DigiD dan weten we wie zij/hij is (identificatie) en kunnen we erop vertrouwen dat dit klopt (authenticatie).
- Als de aanvrager de te uploaden kopie kentekenbewijs verstrekt dan kan vastgesteld worden … etc.
- Als de aanvrager de te uploaden kopie (bromfiets) rijbewijs verstrekt dan kan vastgesteld worden … etc.
- Als de aanvrager aan alle voorwaarden voldoet dan kan de ontheffing verleend worden.
- Voorbeelden uit uw praktijk? Jullie ervaring hiermee?

© 2021, R. van Eijk, BY-NC-SA

Onderbouwen van redenering?

- Wat als de complexiteit van het regelgebaseerde systeem toeneemt?
- Stel, je hebt 10.000 regels nodig om de beslisruimte van het regelgebaseerde systeem vast te leggen?
- Hoe leg je uit hoe dat werkt? Hoe onderbouw je de werking van het systeem? Hoe zorg je ervoor dat je transparant kunt zijn over het systeem?
- Kun je in alle gevallen volledig zijn?

© 2021, R. van Eijk, BY-NC-SA

Gödel's onvolledigheidsstelling

- “Bij een consistent formeel systeem gebaseerd op logica bestaan er altijd beweringen die wel waar zijn, maar niet binnen dit systeem te bewijzen zijn.”
- Deze stelling is gebaseerd op zelfverwijzing: "Deze bewering is onbewijsbaar".
- Twee mogelijkheden:
  1. De bewering is *onwaar*. Met als gevolg dat de bewering *bewijsbaar* is. Dit in tegenspraak met de consistentie van het formele systeem gebaseerd op logica.
  2. De bewering *waar*. Met als gevolg dat de bewering *onbewijsbaar* is. Dit betekent dat het systeem in ieder geval de zelfverwijzing bevat.
- Gödel stelde vervolgens dat - omdat je dit laatste in elk consistent formeel systeem kunt doen - is bewezen dat alle consistente formele systemen gebaseerd op logica onvolledig zijn.
- Gödel’s stelling is daarom een wiskundige stelling die tegelijk iets zegt over de wiskunde zelf als consistent formeel systeem.

© 2021, R. van Eijk, BY-NC-SA

Onderbouwen van redenering?

- We kunnen dus niet in alle gevallen volledig zijn.
- Hoe zorgen we bij toename van de complexiteit voor transparantie, en uitlegbaarheid?
- Een oplossing is uitleggen met tegenvoorbeelden.
- Dit wordt ook wel tegenfeitelijk en contrasterend redeneren genoemd.

© 2021, R. van Eijk, BY-NC-SA

Tegenfeitelijk en contrasterend redeneren (1)

- Tegenfeitelijk redeneren is een centrale notie in sommige verklaringstheorieën.
- Verklaringen moeten informatie verschaffen over wanneer, waarom en hoe effecten of uitkomsten zouden kunnen veranderen of anders zouden kunnen zijn (zie bijv. Woodward, 2003).

Mueller, S. T., Hoffman, R. R., Clancey, W., Emrey, A., & Klein, G. (2019). Explanation in human-AI systems: A literature meta-review, synopsis of key ideas and publications, and bibliography for explainable A, pp. 22-23.

© 2021, R. van Eijk, BY-NC-SA

Tegenfeitelijk en contrasterend redeneren (2)

- Zowel causaal begrip als begrip van concepten impliceert vaak het stellen van hypothetische contrafeitelijke vragen.
- Vragen in de contrafeitelijke vorm
  "**Wat als?**" en "**Wat zou er gebeuren als?**"
- Vragen in de contrastieve vorm
  "**Jij zegt dat het X is, maar waarom is het niet Y?**"
- Deze vragen helpen bij het verkennen van de variatie van categorieën en concepten, en de causale structuur van gebeurtenissen.
- Voorbeelden uit uw praktijk over de juridische verdedigbaarheid van (regel en logica gebaseerde) complexe processen? Jullie ervaring hiermee?

Mueller, S. T., Hoffman, R. R., Clancey, W., Emrey, A., & Klein, G. (2019). Explanation in human-AI systems: A literature meta-review, synopsis of key ideas and publications, and bibliography for explainable A, pp. 22-23.

© 2021, R. van Eijk, BY-NC-SA

iOS privacylabels (sinds December 2020)

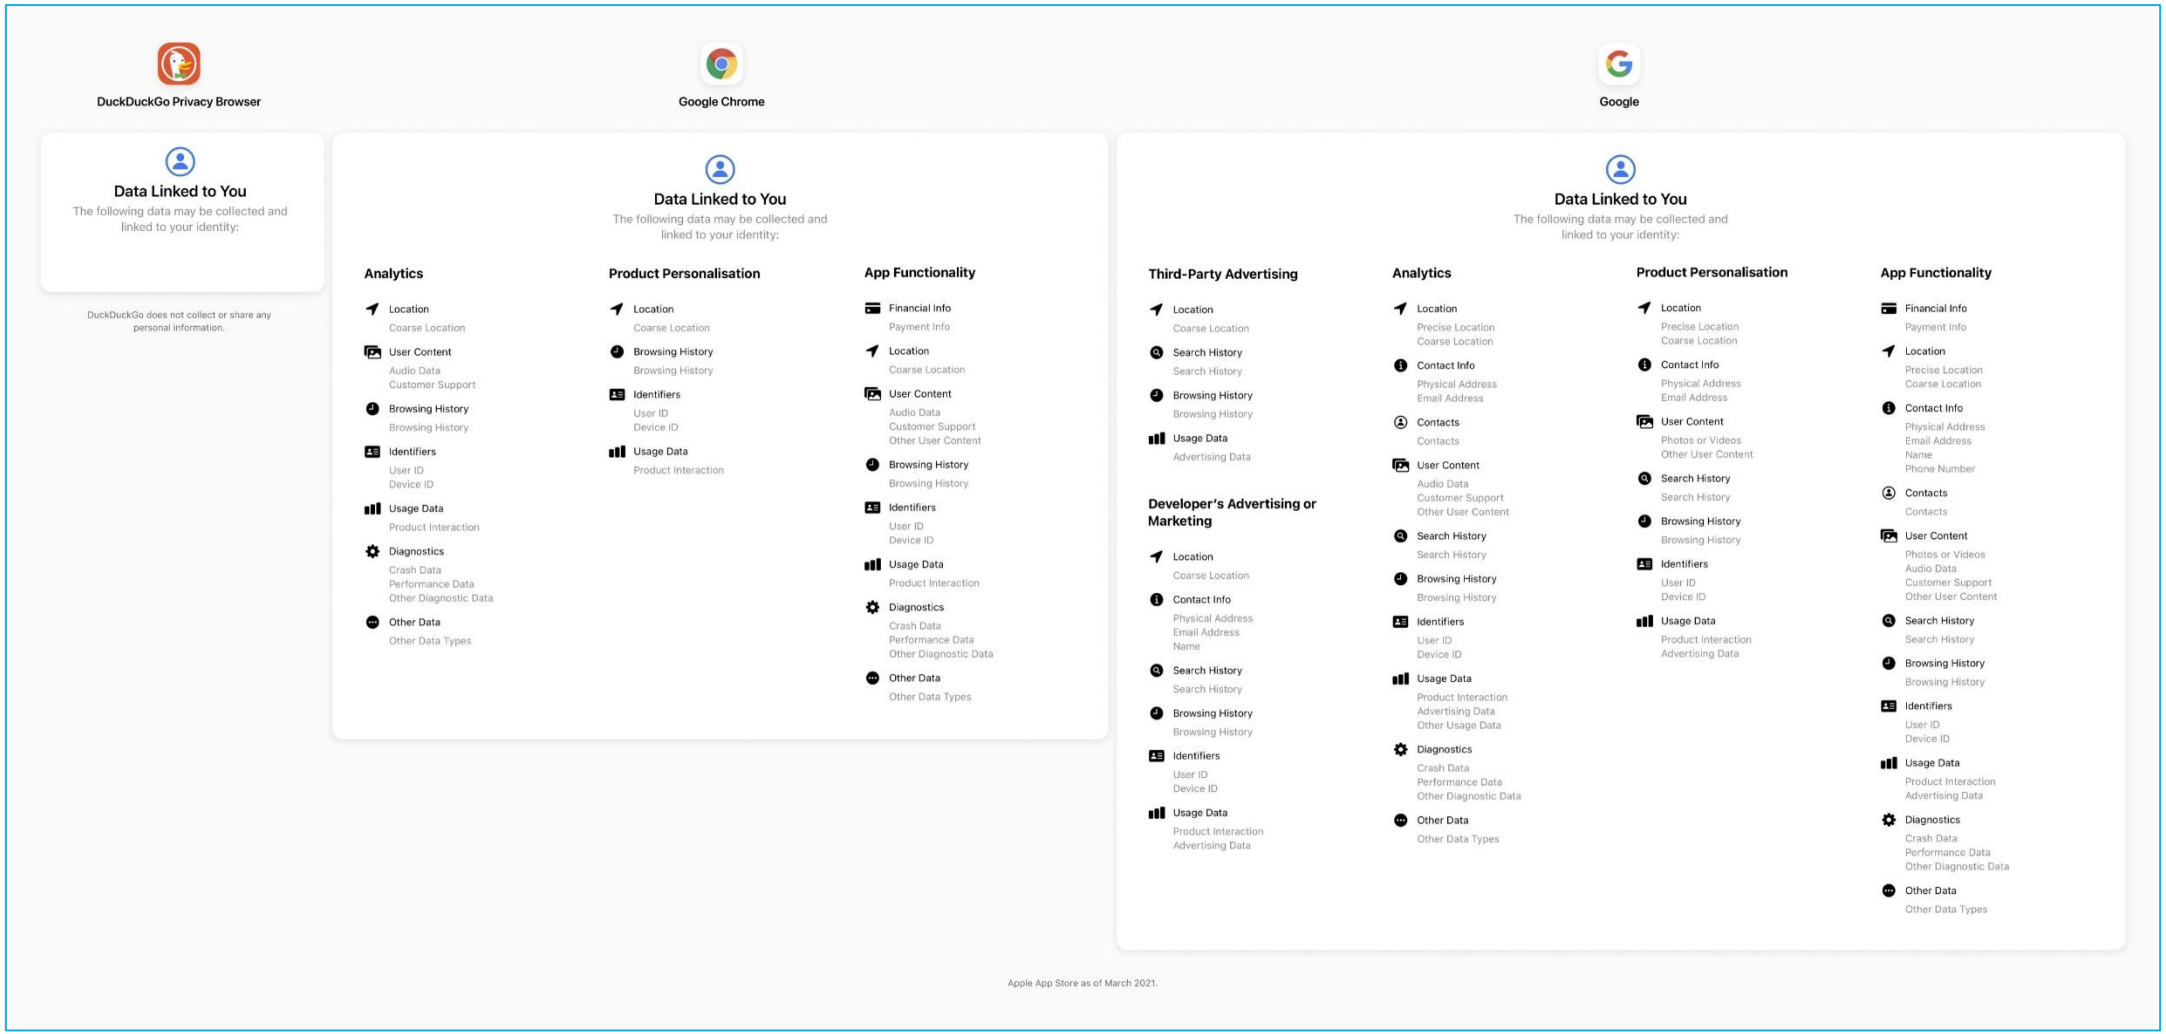

URL: https://twitter.com/DuckDuckGo/status/1371509053613084679/photo/1.

© 2021, R. van Eijk, BY-NC-SA

Van *explanation systems* naar *expert systems* (1)

- Worden ook wel “eerste generatie Explainable AI systemen” genoemd.
- Toepassingen: bijv. beslissingsondersteuning en diagnose.
- “Deze begonnen als systemen die hun interne toestand uitdrukten, en groeiden uit tot systemen die interactiever, contextbewust en flexibel waren, en tot op zekere hoogte in staat waren verklaringen en rechtvaardigingen te bieden die de gebruikers wilden en zouden accepteren.”
- De tekortkomingen van de eerste generatie expertsystemen hebben geleid tot de eerste generatie verklaringssystemen.

Mueller, S. T., Hoffman, R. R., Clancey, W., Emrey, A., & Klein, G. (2019). Explanation in human-AI systems: A literature meta-review, synopsis of key ideas and publications, and bibliography for explainable A, pp. 43-49.

© 2021, R. van Eijk, BY-NC-SA

Van *explanation systems* naar *expert systems* (2)

- Creëren van uitdrukkingen van de logische en probabilistische regels om een diagnose te stellen of een vraag te beantwoorden.
- Kennis en deskundigheid kon in het algemeen in regels werden gevat,
- Met beschrijvingen in natuurlijke taal, afgeleid uit hun logische vorm.
- De regels zelf waren formaliseringen van verbale protocollen.
- Een eenvoudige uitleg zou de regels verwoorden die gebruikt worden om een beslissing te nemen.
- Omzetting van if-then-productieregels in LISP naar tekstbeschrijvingen.

Mueller, S. T., Hoffman, R. R., Clancey, W., Emrey, A., & Klein, G. (2019). Explanation in human-AI systems: A literature meta-review, synopsis of key ideas and publications, and bibliography for explainable A, pp. 43-49.

© 2021, R. van Eijk, BY-NC-SA

Van *explanation systems* naar *expert systems* (3)

- Drie beperkingen waardoor de taalbeschrijvingen nauwelijks gelijkenis vertoonden met menselijke uitleg:
  - Ten eerste waren ze afhankelijk van het als-dan formaat van logische en causale regels, in plaats van een verklaring te geven op een hoger niveau van redeneerstrategie (bijvoorbeeld het verzamelen van basisinformatie over de patiënt, het zoeken naar alternatieve verklaringen, het proberen te ondersteunen van een specifieke hypothese).
  - Ten tweede waren sommige regels logisch gezien noodzakelijk om het systeem te laten werken en niet noodzakelijk zinvol voor de gebruikers of zelfs maar relevant voor de "waarom"-vraag van een gebruiker.
  - Ten derde werd domeinkennis soms "weggestreept" (bv. causale verbanden tussen symptomen en diagnoses), en dus niet in een verklaring opgenomen.

Mueller, S. T., Hoffman, R. R., Clancey, W., Emrey, A., & Klein, G. (2019). Explanation in human-AI systems: A literature meta-review, synopsis of key ideas and publications, and bibliography for explainable A, pp. 43-49.

© 2021, R. van Eijk, BY-NC-SA

Van *explanation systems* naar *expert systems* (4)

- Hoewel regelgebaseerde systemen het huidige doel (b.v. het bepalen van het type infectie) en de voorwaarden van een regel in een verklaring konden weergeven, werd niet weergegeven waarom de regel juist was.
- Een duidelijk voorbeeld is de Mycin-regel: "Als de patiënt een infectie heeft en in de San Joaquin-vallei woont, kan het infectietype schimmel zijn."
- Hoe het wonen in de San Joaquin Valley een infectie veroorzaakt, is niet opgenomen in Mycin's model van ziekten en therapieën.
- Bovendien waren de clausules in het "als"-gedeelte vaak geordend; in de bovenstaande regel bijvoorbeeld test de tweede clausule op bewijs voor een subtype van de ziektecategorie (is het schimmel?) die door de eerste clausule wordt vastgesteld (er is bewijs voor een infectie).

Mueller, S. T., Hoffman, R. R., Clancey, W., Emrey, A., & Klein, G. (2019). Explanation in human-AI systems: A literature meta-review, synopsis of key ideas and publications, and bibliography for explainable A, pp. 43-49.

© 2021, R. van Eijk, BY-NC-SA

Handvatten voor (juridische) verdedigbaarheid? (1)

Triggers	User/Learner's Goal	
	Need to Understand	Need to Accomplish
How do I use it?	Use	Primary task goals
How does it work?	Mechanism, Understandability	Feeling of Satisfaction
What did it just do?	Mechanism, Understandability	Feeling of Sufficiency
What does it achieve?	Function	Usefulness
What will it do next?	Observability	Trust, Reliance
How much effort will this take?	Usability	Primary Task Goals
What do I do if it gets it wrong?	Anticipation	Control
How do I avoid the failure modes?	Surprise	Adaptation, Work-around
What would it have done if x was different?	Mechanism, Understandability	Curiosity, Trust, Reliance
Why didn't it do z?	Anticipation, Surprise	Curiosity, Trust, Reliance

Mueller, S. T., Hoffman, R. R., Clancey, W., Emrey, A., & Klein, G. (2019). Explanation in human-AI systems: A literature meta-review, synopsis of key ideas and publications, and bibliography for explainable A, p. 90.

© 2021, R. van Eijk, BY-NC-SA

Handvatten voor (juridische) verdedigbaarheid? (2)

Format (How it is expressed)	Reference (What it is about)
• Visualizations (e.g., Heat maps) • Text (Statements, Narratives or Stories, Answers to queries, Human-machine dialogs) • Formal Expressions (Logical expressions, Matrices) • Conceptual Process Models (Diagrams) • Graphs, Networks • Tables • Abstractions, generalizations • Timelines • Hierarchies (Trees)	• Examples (includes misclassifications, counter-examples, outliers, clear cases, close competitors) • Patterns, Classes, Ontologies • Features, Weights, Probabilities, Ranks, Parameters • Decisions, Strategies, Goals • Algorithms, Computational Processes, Proofs • Incidents, Events (includes self-explanations or stories) • Cause-effect relations

Mueller, S. T., Hoffman, R. R., Clancey, W., Emrey, A., & Klein, G. (2019). Explanation in human-AI systems: A literature meta-review, synopsis of key ideas and publications, and bibliography for explainable A, p. 84.

© 2021, R. van Eijk, BY-NC-SA

Handvatten voor (juridische) verdedigbaarheid? (3)

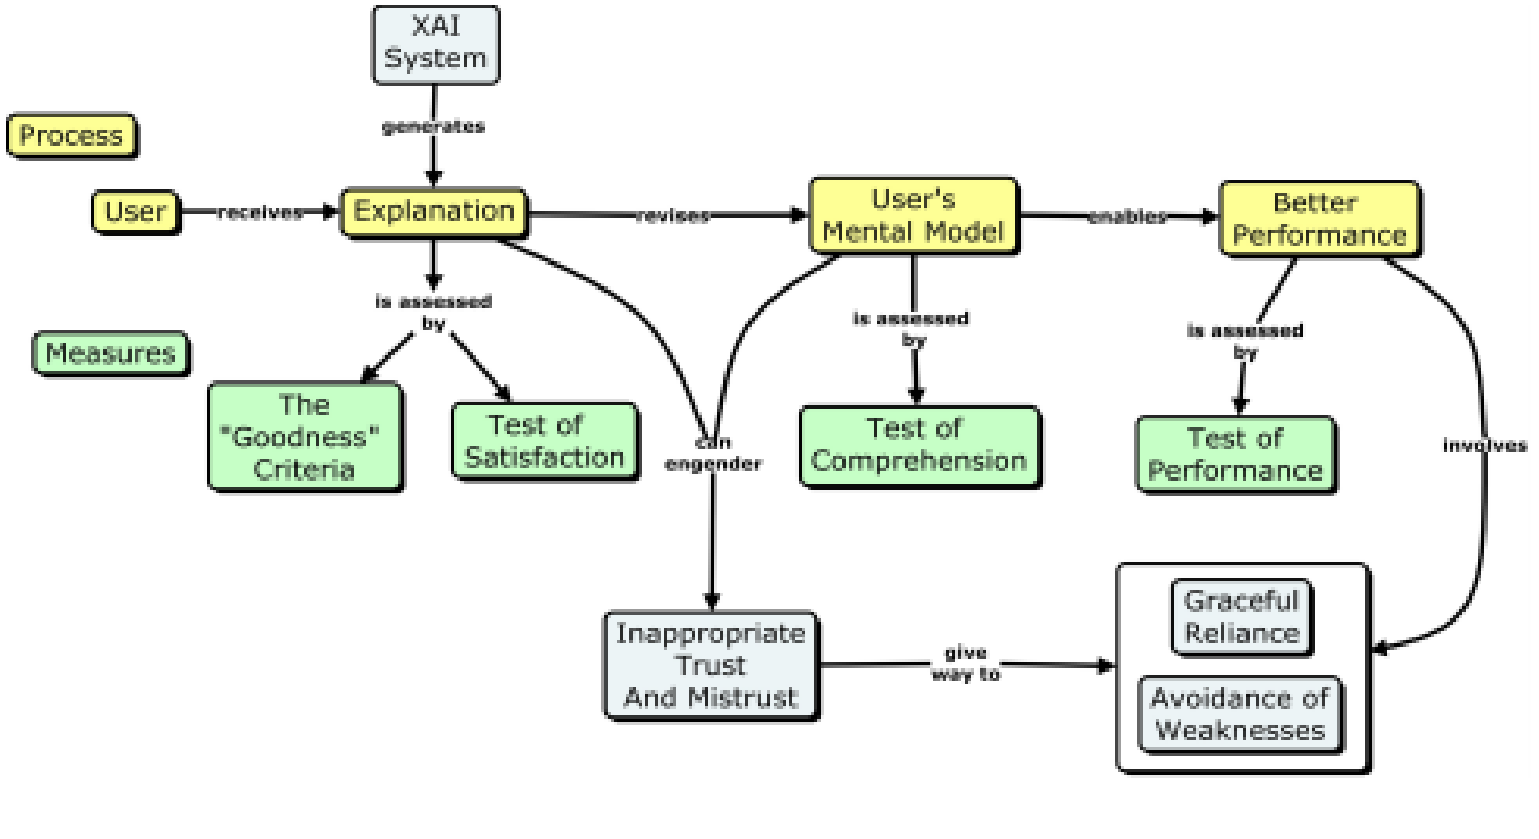

Figure 8.1. DARPA's XAI Evaluation Framework. Explanations should induce better mental models and performance, which produce appropriate trust in the system.

Mueller, S. T., Hoffman, R. R., Clancey, W., Emrey, A., & Klein, G. (2019). Explanation in human-AI systems: A literature meta-review, synopsis of key ideas and publications, and bibliography for explainable A, p. 99.

© 2021, R. van Eijk, BY-NC-SA

FAT/ML

- Principles for Accountable Algorithms and a Social Impact Statement for Algorithms

Explainability

Ensure that algorithmic decisions as well as any data driving those decisions can be explained to end-users and other stakeholders in non-technical terms.

URL: https://www.fatml.org/resources/principles-for-accountable-algorithms.

© 2021, R. van Eijk, BY-NC-SA

- Princi
  Impac

Explainability

Ensure that algorithmic decis
other stakeholders in non-tec

Explainability

Guiding Questions

- Who are your end-users and stakeholders?
- How much of your system / algorithm can you explain to your users and stakeholders?
- How much of the data sources can you disclose?

Initial Steps to Take

- Have a plan for how decisions will be explained to users and subjects of those decisions. In some cases it may be appropriate to develop an automated explanation for each decision.
- Allow data subjects visibility into the data you store about them and access to a process in order to change it.
- If you are using a machine-learning model:
  - consider whether a directly interpretable or explainable model can be used.
  - describe the training data including how, when, and why it was collected and sampled.
  - describe how and when test data about an individual that is used to make a decision is collected or inferred.
- Disclose the sources of any data used and as much as possible about the specific attributes of the data. Explain how the data was cleaned or otherwise transformed.

URL: https://www.fatml.org/resources/principles-for-accountable-algorithms.

© 2021, R. van Eijk, BY-NC-SA

- Princi
  Impac

Explainability

Guiding Questions

- Who are your end-users and stakeholders?
- How much of your system / algorithm can you explain to your users and stakeholders?
- How much of the data sources can you disclose?

Initial Steps to Take

- Have a plan for how decisions will be explained to users and subjects of those decisions. In some cases it may be appropriate to develop an automated explanation for each decision.
- Allow data subjects visibility into the data you store about them and access to a process in order to change it.
- If you are using a machine-learning model:
  - consider whether a directly interpretable or explainable model can be used.

Explainability

pled.

ion is collected or

utes of the data.

Fairness

Ensure that algorithmic decisions do not create discriminatory or unjust impacts when comparing across different demographics (e.g. race, sex, etc).

We have left some of the terms above purposefully under-specified to allow these principles to be broadly applicable. Applying these principles well should include understanding them within a specific context. We also suggest that these issues be revisited and discussed throughout the design, implementation, and release phases of development. Two important principles for consideration were purposefully left off of this list as they are well-covered elsewhere: privacy and the impact of human experimentation. We encourage you to incorporate those issues into your overall assessment of algorithmic accountability as well.

URL: https://www.fatml.org/resources/principles-for-accountable-algorithms.

© 2021, R. van Eijk, BY-NC-SA

- Princi
  Impac

Explainability

Fairness

Ensure that algorithmic decisio
demographics (e.g. race, sex, e

We have left some of the terms
applicable. Applying these prin
suggest that these issues be re
of development. Two importan
covered elsewhere: privacy an
issues into your overall assess

Explainability

Fairness

Guiding Questions

- Are there particular groups which may be advantaged or disadvantaged, in the context in which you are deploying, by the algorithm / system you are building?
- What is the potential damaging effect of uncertainty / errors to different groups?

Initial Steps to Take

- Talk to people who are familiar with the subtle social context in which you are deploying. For example, you should consider whether the following aspects of people's identities will have impacts on their equitable access to and results from your system:
- Race
- Sex
- Gender identity
- Ability status
- Socio-economic status
- Education level
- Religion
- Country of origin
- If you are building an automated decision-making tool, you should deploy a fairness-aware data mining algorithm. (See, e.g., the resources gathered at http://fatml.org).
- Calculate the error rates and types (e.g., false positives vs. false negatives) for different sub-populations and assess the potential differential impacts.

URL: https://www.fatml.org/resourc

© 2021, R. van Eijk, BY-NC-SA

AI and data protection risk mitigation and management toolkit

- Gepubliceerd door de Information Commissioner’s Office (ICO).
- De publieke consultatie is gestart (15 maart 2021 tot 19 april 2021).
- De toolkit is bedoeld om risicoprofessionals te helpen de gegevensbeschermingsrisico's die AI-systemen veroorzaken of verergeren, in kaart te brengen en te beperken.
- 13 invalshoeken, waaronder
  - transparantie,
  - statistische nauwkeurigheid,
  - discriminatie en
  - data minimalisatie.

URL: https://ico.org.uk/about-the-ico/ico-and-stakeholder-consultations/ai-and-data-protection-risk-mitigation-and-management-toolkit/.

© 2021, R. van Eijk, BY-NC-SA

Number	Risk	How AI can create or exacerbate this risk	Probability (1 = Low, 2 = low/medium, 3 =	Severity (1= low, 2 = low/medium, 3 =	Risk score (probability x severity)	Current status of the risk	Practical steps you could take	Intended action(s)
10,1	Using AI to process personal data without informing individuals impinges on human dignity and a breach of UK GDPR Articles 13, 14 and 22.	AI systems may be opaque, undermining transparency and interpretability of decisions.			0		o Publish privacy information that is concise, transparent, intelligible and uses clear and plain language. o Ensure the privacy information includes meaningful information about the logic involved, as well as the significance and envisaged consequences of the processing for individuals. o Tailor explanations to the intended audience so that they are clear and easy for individuals to understand, considering the level of knowledge that the explanation recipient has about the subject. o Ensure that the privacy information includes the purposes of the processing and the lawful bases (and the legitimate interests for the processing if applicable). o Explain any trade-offs to individuals or any human tasked with reviewing AI output. o Provide privacy information to individuals at the time their personal data is collected (unless an exemption applies). o Ensure individuals are made aware of the privacy information and have an easy way to access it, eg using a combination of appropriate techniques, such as a layered approach, dashboards, just-in-time notices, icons and mobile and smart device functionalities. o Provide details enabling individuals to challenge the outcome if they think it is flawed (eg if some of the input data was incorrect or irrelevant, or additional data wasn't taken into account that the individual thinks is relevant).	
10,2	Failure to provide information to individuals where that information was not obtained from the individual leads to unfair invisible processing, a reduction of human autonomy and a	Datasets containing personal data that are used for training AI purposes may be shared among multiple organisations without the individual's knowledge.					o Carry out due diligence of potential data suppliers to confirm appropriate privacy information has been provided to data subjects. o Carry out a DPIA to determine whether providing privacy information would involve a disproportionate effort when	

... | 5. Lawful Basis | 6. Trade offs | 7. Statistical accuracy | 8. Discrimination | 9. Security & integrity | 10. Transparency | 11. Data minimisation | 12. Individual rights | 13. Human review

URL: https://ico.org.uk/about-the-ico/ico-and-stakeholder-consultations/ai-and-data-protection-risk-mitigation-and-management-toolkit/.

© 2021, R. van Eijk, BY-NC-SA

Number	Risk	How AI can create or exacerbate this risk	Probability (1 = Low, 2 = low/medium, 3 =	Severity (1= low, 2 = low/medium, 3 =	Risk score (probability x severity)	Current status of the risk	Practical steps you could take	Intended action(s)
7,1	A lack of structured testing processes in place leads to pre-implementation testing not being undertaken or completed effectively.	There are several different ways of measuring the statistical accuracy of an AI system.			0		o Put in place a policy / documented process that includes details of how the system will be tested prior to implementation. o Ensure the 'test plan' includes all the relevant checks to ensure that there are no errors in data outputs or statistical errors. o Ensure the test plan includes documented tolerances for errors. o Document the results of the testing. o Ensure that acceptance of the test results is signed off by management. o Retrain the AI system following testing (eg by improving input data, different balance of false positives and negatives, or using different learning algorithms). o Test the AI system on new data set(s) to confirm the same outcome is reached. o Ensure that testing was completed prior to the deployment of the AI system.	
7,2	Failure to have structured testing processes in place leads to human review not being undertaken or completed effectively.	Complex AI systems may lead to automation bias.			0		o Put in place a policy / documented process that includes details of the methodology that will be used by a human reviewer when testing the system for statistical accuracy. o Put in place a testing process that outlines the test plan criteria, requirements, and sampling method / size. o Ensure the 'test plan' includes all the relevant checks to ensure that the rate of error in data outputs or statistical errors is within acceptable and documented tolerances. o Ensure the test plan includes documented tolerances for errors. o Document the results of the testing. o Ensure that acceptance of the test results is signed off by management.	

... | 5. Lawful Basis | 6. Trade offs | 7. Statistical accuracy | 8. Discrimination | 9. Security & integrity | 10. Transparency | 11. Data minimisation | 12. Individual rights | 13. Human review

URL: https://ico.org.uk/about-the-ico/ico-and-stakeholder-consultations/ai-and-data-protection-risk-mitigation-and-management-toolkit/.

© 2021, R. van Eijk, BY-NC-SA

Number	Risk	How AI can create or exacerbate this risk	Probability (1 = Low, 2 = low/medium, 3 =	Severity (1= low, 2 = low/medium, 3 =	Risk score (probability x severity)	Current status of the risk	Practical steps you could take	Intended action(s)
8,1	Failure to review the system's design leads to bias or discriminatory outputs being built into the system	AI systems may lead to unjust discriminatory outcomes if training data is discriminatory.			0		o Ensure that risks are drawn from policy, user research and design, and computer science expertise. o Ensure that the review includes all the relevant checks to the design of the AI systems to ensure that there isn't the potential for discriminatory outputs or decisions to be made. o Ensure that reviews are conducted by appropriately skilled and experienced technical 'experts'. o Document the results of the reviews, including any trade-offs and their technical implications o Ensure that reviews are signed off by senior management. o Document where the AI system design has been adapted / changed following the review where necessary.	
8,2	Failure to use protected characteristics to ensure fairness/accuracy (as defined by the goals of the system) leads to data subjects facing inaccurate or unfair results.	AI systems may use other data points as a proxy for characteristics leading to unlawful discriminatory outcomes that are difficult to detect.			0		o Document considerations and the results of any internal consultations. o Document where possible positive discriminatory characteristics have been included in the system. o Ensure these characteristics are tested thoroughly to ensure they produce the right outputs consistently.	
8,3	No structured testing process in place leads to pre-implementation testing not being undertaken or completed effectively.	There are several different ways of measuring the statistical accuracy of an AI system.			0		o Put in place a policy / documented process that includes details of how the system will be tested prior to implementation. o Ensure the 'test plan' includes all the relevant checks to ensure that there are no discriminatory outputs or decisions (or that these decisions / outputs are at a necessary minimum level) made within AI systems. o Document the results of the testing. o Ensure that the acceptance of the test results is signed off by senior management. o Document where the AI system has been 'retrained' following testing (eg by implementing algorithmic fairness measures / fairness constraints).	

... | 5. Lawful Basis | 6. Trade offs | 7. Statistical accuracy | 8. Discrimination | 9. Security & integrity | 10. Transparency | 11. Data minimisation | 12. Individual rights | 13. Human review

URL: https://ico.org.uk/about-the-ico/ico-and-stakeholder-consultations/ai-and-data-protection-risk-mitigation-and-management-toolkit/.

© 2021, R. van Eijk, BY-NC-SA

Number	Risk	How AI can create or exacerbate this risk	Probability (1 = Low, 2 = low/medium, 3 =	Severity (1= low, 2 = low/medium, 3 =	Risk score (probability x severity)	Current status of the risk	Practical steps you could take
11,1	A lack of reviews at each stage of the AI lifecycle leads to a risk of inappropriate retention of data and non-compliance with Article 5 (1) (c)	AI systems generally require large amounts of data			0		o Assess whether the features used to train the AI system – and therefore the data – are relevant for the purpose, and make sure in the design stage only that data is processed o Do an assessment to ensure the training data can be modified to reduce the extent to which it can be traced back to specific individuals o Include specific review phases in your development plan to check data is being minimised / not retained when no longer needed. o Do an assessment that includes a justification for the retention of data where applicable o Remove or delete irrelevant data during the system development phase. Maintain a record of what data was removed or deleted.
11,2	Data that is not assessed for its relevance and then separated and deleted leads to excessive data being retained for longer than is necessary and non-compliance with Article 5 (1), (c).	AI systems may find some data points statistically irrelevant.			0		o Map out all the processes in which personal data is used in the different phases of an AI system. o Ensure that the mapping and then subsequent assessment for the potential minimisation of data includes data used in the production of the system and then as part of ongoing research to retrain the system o Index the personal data used in each phase of the AI system lifecycle. o Design a process that detects any duplicated data present in different phases (from production to research) and delete where necessary.

... | 5. Lawful Basis | 6. Trade offs | 7. Statistical accuracy | 8. Discrimination | 9. Security & integrity | 10. Transparency | 11. Data minimisation | 12. Individual rights | 13. Human review

URL: https://ico.org.uk/about-the-ico/ico-and-stakeholder-consultations/ai-and-data-protection-risk-mitigation-and-management-toolkit/.

© 2021, R. van Eijk, BY-NC-SA

Autoriteit Consument en Markt (10 Dec 2020) Position paper Toezicht op algoritmen

Onderzoek naar toezicht op algoritmische toepassingen

Dit position paper is een vertrekpunt van waaruit de ACM het toezicht op algoritmische toepassingen verder wil ontwikkelen. Het biedt algemene handvatten voor onderzoeken naar overtredingen waarbij algoritmische toepassingen een rol spelen.

De ACM beschrijft in het position paper wat algoritmische toepassing zijn en wanneerzij relevant zijn voor de ACM. Vervolgens licht de ACM toe hoe zij in de praktijk algoritmische toepassingen kan onderzoeken en bespreekt zij enkele uitdagingen waar zij in de praktijk mee te maken kan krijgen.

De ACM draagt met deze publicatie bij aan de nationale en internationale discussie over de toepassing van AI (artificiële intelligentie) door bedrijven en het toezicht daarop door toezichthouders.

Wachter S., Mittelstat B. & Rusell C. (2021). Bias Preservation in Machine Learning: The Legality of Fairness Metrics Under EU Non-Discrimination Law. In: *West Virginia Law Review, Forthcoming.*

© 2021, R. van Eijk, BY-NC-SA

Autoritei Dec 2020)
Posi oritmen

Onde algo

Dit position pa erder wil ontwikkelen.
Het biedt alge gen een rol spelen.

De ACM besch or de ACM. Vervolgens
licht de ACM t ele uitdagingen waar zij
in de praktijk r

De ACM draag an AI (artificiële
intelligentie) d

Fairness metrics	Bias preserving?
1. Group fairness, Statistical (demographic) parity[i]	✗
2. Conditional statistical (demographic) parity, Conditional independence[ii]	✗
3. Predictive parity, outcome test[iii]	✓
4. False positive error rate balance[iv]	✓
5. False negative error rate balance,[v] Equal opportunity[vi]	✓
6. Equalized odds[vii]	✓
7. Conditional use accuracy equality[viii]	✓
8. Overall accuracy equality[ix]	✓
9. Treatment equality[x]	✓
10. Test-fairness or calibration[xi]	✓
11. Well-calibration[xii]	✓
12. Balance for positive class[xiii]	✓
13. Balance for negative class[xiv]	✓
14. Causal discrimination[xv] (direct discrimination)	*
15. Fairness through unawareness[xvi]	*
16. Fairness through awareness[xvii]	✗
17. Counterfactual fairness[xviii]	✗
18. No unresolved discrimination[xix] (causal variant of 2)	✗
19. No proxy discrimination[xx]	✗
20. Path based causal reasoning[xxi]	✗

Wachter S., Mittelstat B. & Rusell C. (2021). Bias Preservation in Machine Learning: The Legality of Fairness Metrics Under EU Non-Discrimination Law. In: *West Virginia Law Review, Forthcoming.*

© 2021, R. van Eijk, BY-NC-SA

Dank voor uw aandacht

Universiteit Leiden
The Netherlands

Contact:

rob@blaeu.com
@rvaneijk (Twitter)

rvaneijk@fpf.org
rvaneijk88 (Linkedin)

FUTURE OF PRIVACY FORUM