Dr. Rob van Eijk
Future of Privacy Forum

Leiden Legal Tech Program

Legal and policy applications of non-linear Data Science models

Universiteit Leiden
Leiden Centre of Data Science

FUTURE OF PRIVACY FORUM

© 2021, R. van Eijk, BY-NC-SA

Universiteit Leiden

Wat zijn toepassingen gerelateerd aan de juridische en beleidsmatige praktijk?

- Gericht adverteren vereist toestemming voor cookies
- Contextueel adverteren zonder toestemming
- Het R-getal (COVID-19)

De waardeketen van digitale advertenties

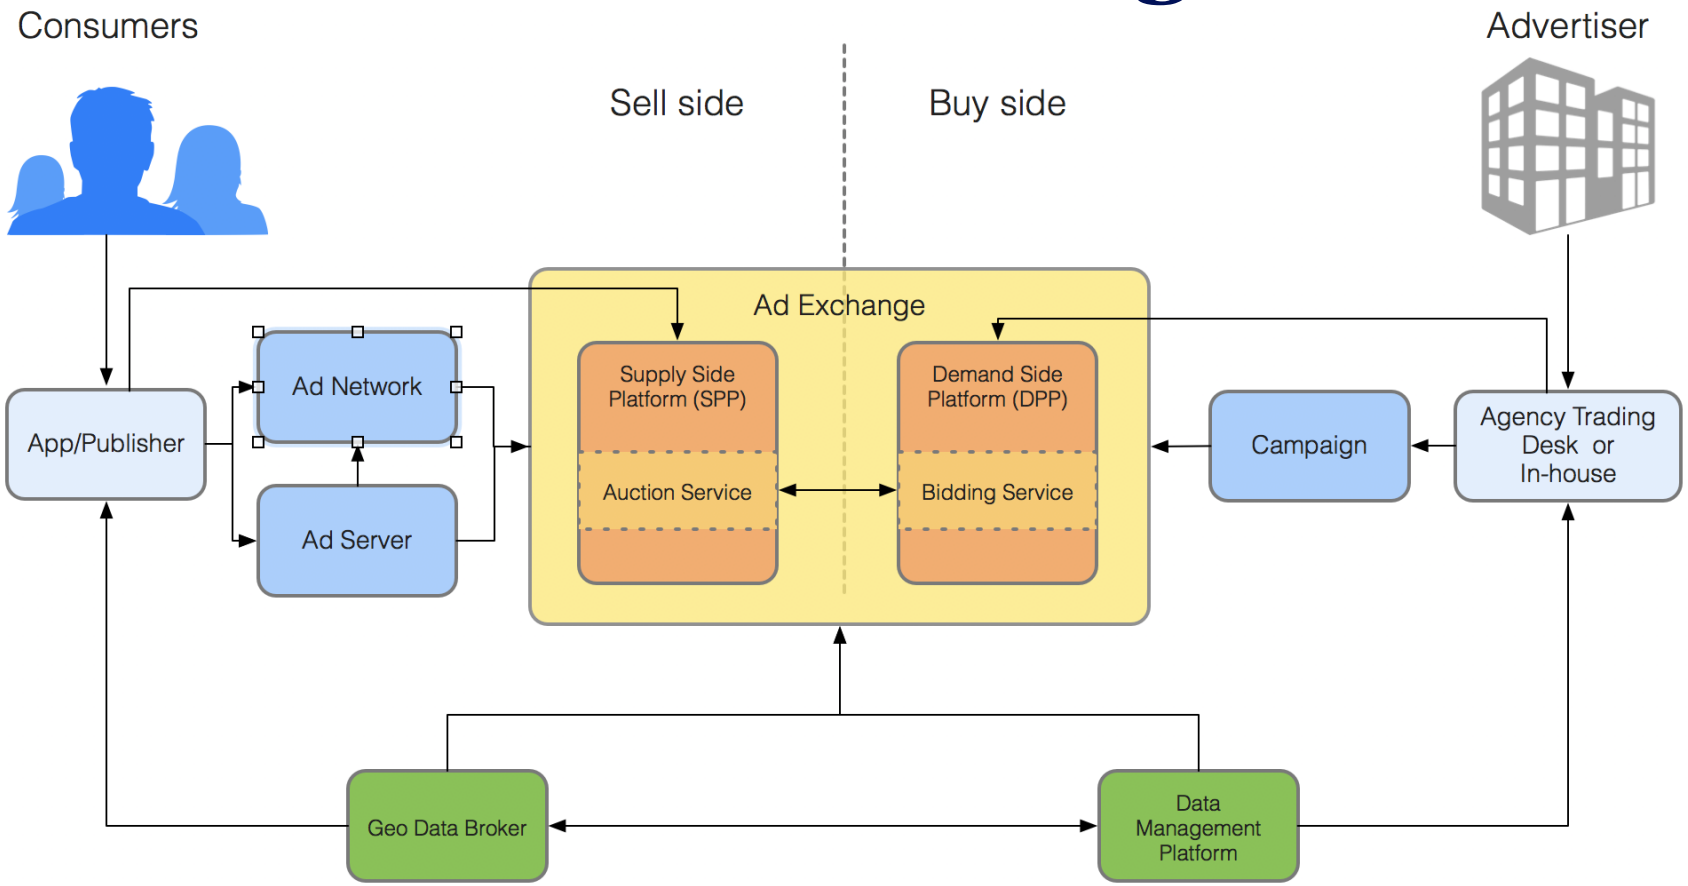

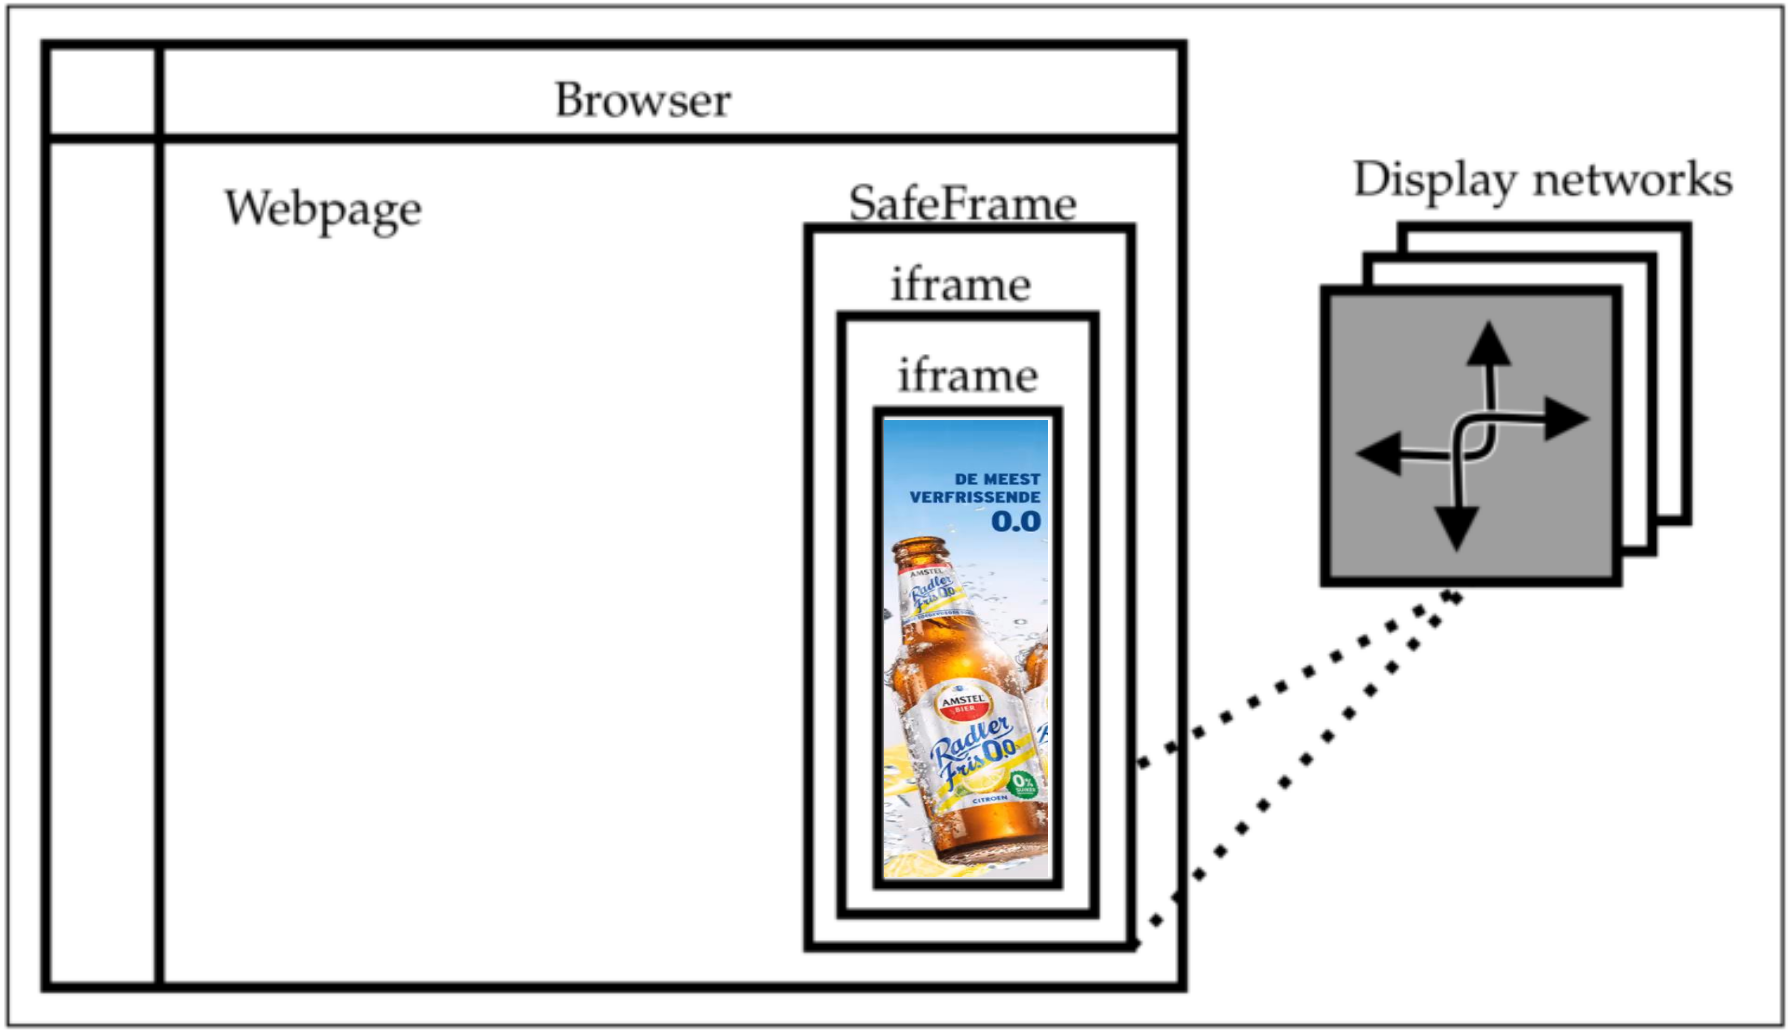
Browser
Webpage
SafeFrame
iframe
iframe
DE MEEST
VERFRISSENDE
0.0
AMSTEL
Radler
Fris 0.0
Display networks

alle	cookie	CSS	afb.	media	script	XHR	frame	overig
Huidige domein								
2mdn.net								
s0.2mdn.net		1	14		5			
ajax.googleapis.com					1			

Google Doubleclick Frame:
https://s0.2mdn.net/9026094/1559035272353/amnet_160x600/index.html

Tracking cookie als classificatieprobleem

- Manifest
- Service Workers
- Storage

orage

- Local Storage
  - https://www.vivitas.nl
- Session Storage
  - https://www.vivitas.nl
- IndexedDB
- Web SQL
- Cookies
  - https://www.vivitas.nl
- Trust Tokens

Name	Value	Domain	P.	Expires / Max-A...	Size	Http...	Secure	Sa...	Sam...	Priori...
_gat_UA-154593133-1	1	.vivitas.nl	/	2021-06-10T15:...	20					Medi...
wordpress_allow_cookies	1	www.vivitas.nl	/	2022-06-10T15:...	24					Medi...
_gid	GA1.2.458151446.16233...	.vivitas.nl	/	2021-06-11T15:...	30					Medi...
PHPSESSID	e3eff6108a0016043ed4f...	www.vivitas.nl	/	Session	41					Medi...
CookieConsent	{"NECESSARY":true,"PRE...	www.vivitas.nl	/	2022-06-10T15:...	85					Medi...
_ga	GA1.2.2052327425.1623...	.vivitas.nl	/	2023-06-10T15:...	30					Medi...

Shannon entropie [1]

- We beschouwen een **tracking cookie** als een cookie met een waarde van ten minste 13 bits (Shannon) entropie.
- Dat is voldoende om een individu in een groep van 5.000 mensen te identificeren.

Shannon entropie [2]

- $H(X) = -\sum_{i=1}^{n} P(x_i) \log_j P(x_i)$

> DEFINITION 3.12: SHANNON ENTROPY is defined to be the Shannon entropy H of a random variable X, with a logarithmic base value j of 2, with outcomes $\{x_1, \ldots, x_n\}$, and a probability $P(x_i)$.

- Voorbeeld voor een dobbelsteen:
  - De Shannon-entropie van een enkele worp met een perfecte dobbelsteen wordt bepaald bepaald door de zes zijden.
  - Omdat de kans P(xi) van de perfecte dobbelsteen voor elk getal gelijk is (1/6), is de entropie H ongeveer 2,58 bits binaire informatie voor de uitkomst van één worp met de dobbelsteen.

Eijk R. van (2019). Web Privacy Measurement in Real-Time Bidding Systems. A Graph-Based Approach to RTB System Classification. (diss. Leiden).

Aanpak met support-vector machines [1]

- Feature selectie voor de cookienaam en de cookiewaarden
- De kenmerken om het SVM-model te trainen zijn de volgende:
  - De lengte van de cookiewaarde
  - Het aantal verschillende tekens
  - Het aantal karakters in elk van de volgende karaktersets:
  - "abcdefghijklmnopqrstuvwxyz"
  - "ABCDEFGHIJKLMNOPQRSTUVWXYZ"
  - "01234567890"
  - "_:/.%"

Aanpak met support-vector machines [2]

- Corpus met tracking cookies: 6.162 (handmatig verzameld).
- Drie voorbeelden trainingset van tracking cookies”:
  - {"k": "khaos", "v": "IOGYD99W-2-JB1P"}
  - {"k": "uuid2", "v": "99018324164131 1709"}
  - {"k": "KRTBCOOKIE_153", "v": "1923-t3tgKOB0YX2veWErtX55fuB-NSqvemx7snk94_MS&KRTB&19420-t3tgKOB0YX2veWErtX55fuB-NSqvemx7snk94_MS"}

Aanpak met support-vector machines [3]

- Corpus met *niet*-tracking cookies: 1.682 (handmatig verzameld)
- Drie voorbeelden uit de training set van ‘geen tracking cookies’:

  - {"k": "EmailPopup", "v": "1"}
  - {"k": "_gat", "v": "1"}
  - {"k": "ServedBy", "v": "beacon-a142"}

Aanpak met support-vector machines [4]

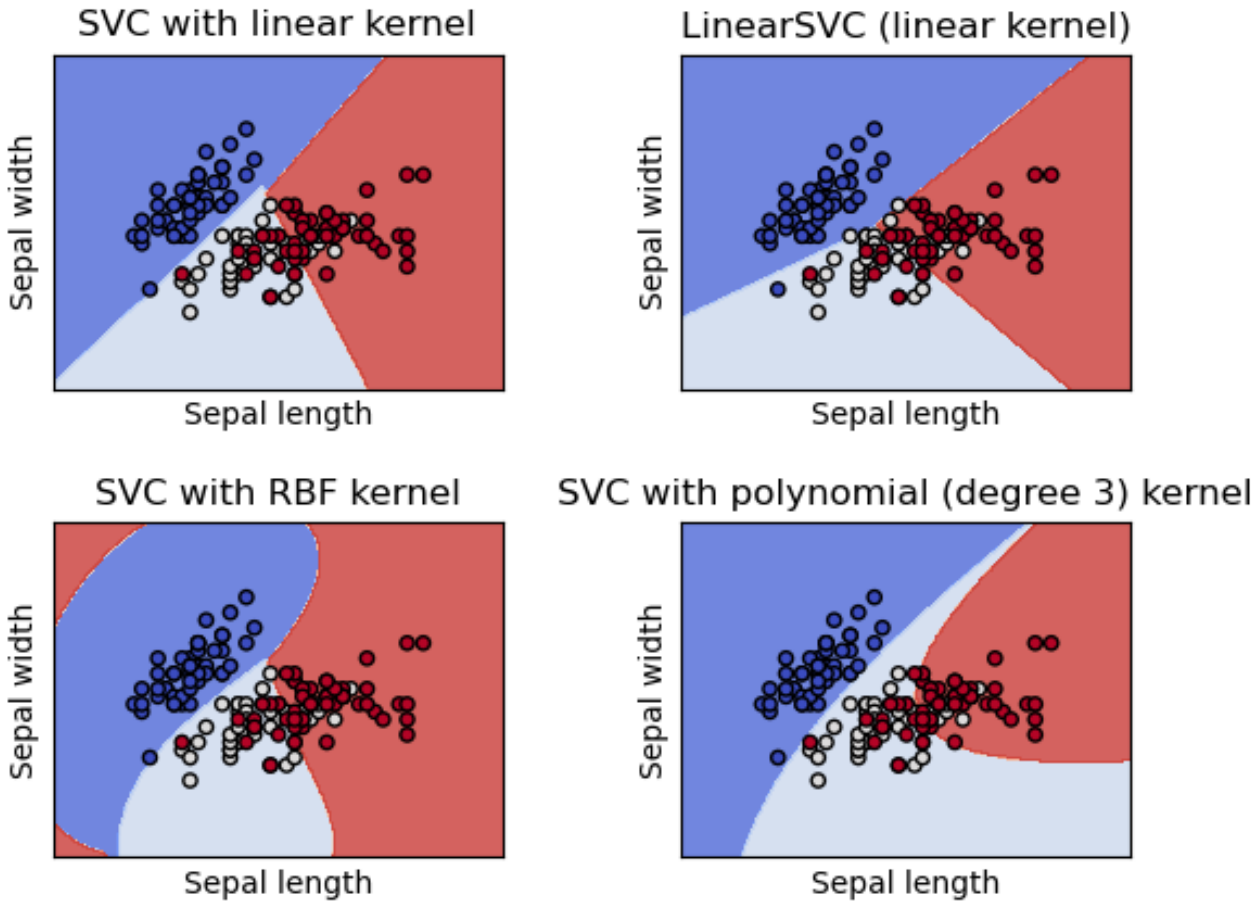

https://scikit-learn.org/stable/modules/svm.html#svm-classification

```python
import os
import pickle
from sklearn import svm

DATA_DIR = "data"
CLASSIFIER_FILE = "./data/cookie_tracking_classifier"

sets = [
    set("abcdefghijklmnopqrstuvwxyz"),
    set("ABCDEFGHIJKLMNOPQRSTUVWXYZ"),
    set("01234567890"),
    set("_:/.%"),
]

def new_classifier():
    return svm.SVC(kernel="rbf", cache_size=1000, C=5)


def save_classifier(cfr):
    pickle.dump(cfr, open(CLASSIFIER_FILE, "wb"))


def load_classifier():
    return pickle.load(open(CLASSIFIER_FILE, "rb"))
```

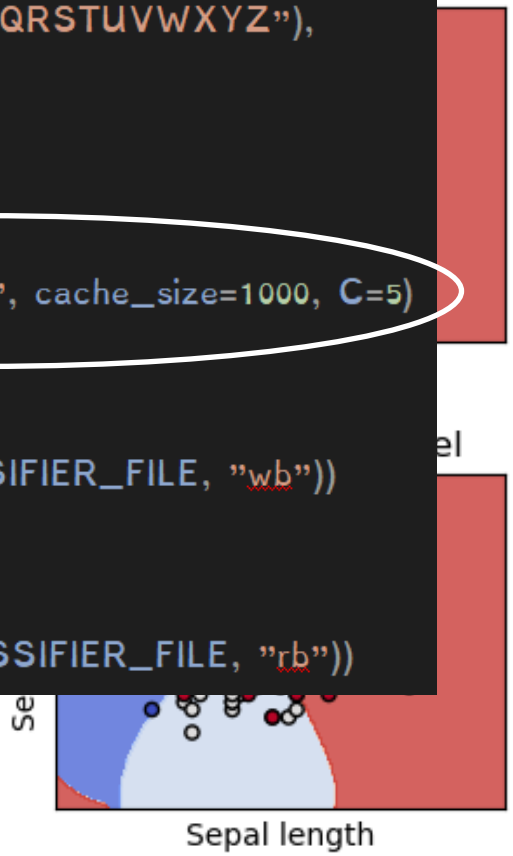


```python
def train(save=False):
    notrack, track = get_data()
    data = notrack + track
    random.shuffle(data)

    mid = len(data)/2
    train, test = data[:mid], data[mid:]

    clf = ct.new_classifier()
    print clf
    clf.fit(
        [ct.features(i["k"], i["v"]) for i in train],
        [i["c"] for i in train]
    )

    score = 0
    for i in test:
        if i["c"] == clf.predict([ct.features(i["k"], i["v"])])[0]:
            score += 1
        else:
            print(i)

    print "Score: %.2f%%" % (float(score)/len(test) * 100)
    if save:
        ct.save_classifier(clf)
```

https://scikit-learn.org/stable/modules/svm.html#svm-classification

Drie observaties

- Entropie presteerde slecht op korte cookie-waarden,
- Entropie kwam niet overeen met de intuïtie voor gestructureerde gegevens in langere cookie-waarden, en
- Entropie maakte geen onderscheid tussen sessie-cookies die niet in de browser blijven en tracking cookies die wel achterblijven in de browser.

Sterke correlatie

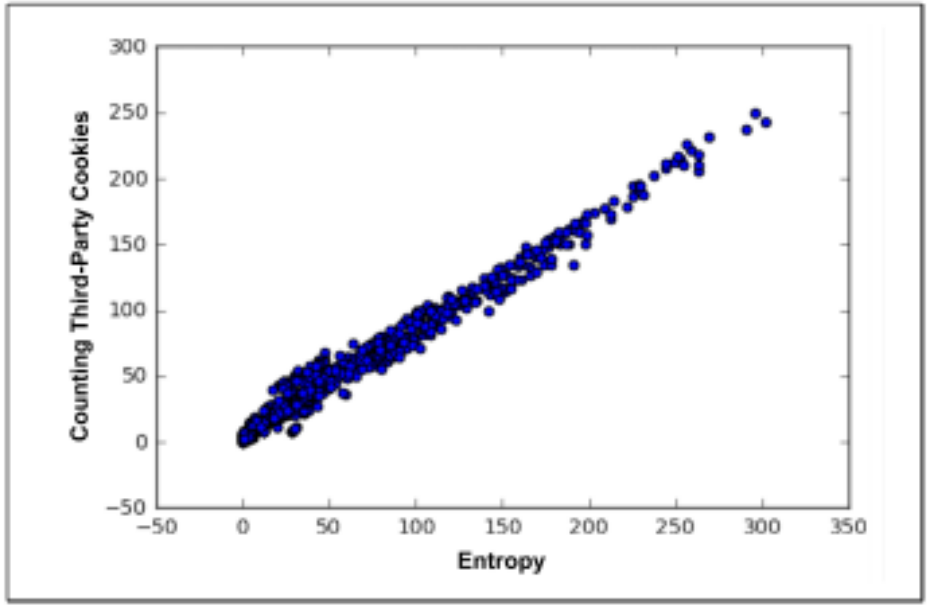

Figure 3.5: Entropy versus Counting Third-Party Cookies (CTPC): Spearman's correlation coefficient = 0.9575871354780891 6, pvalue = 0.0 [Asghari et al., 2016].

- Twee variabelen,
- Bijna lineair,
- Zeg, $\alpha=40^{\circ}$, in $y=\alpha x$,
- Er is geen verschil tussen het tellen van tracking cookies en de entropie van de cookies.

Entropie werkt niet: andere feature(s)?

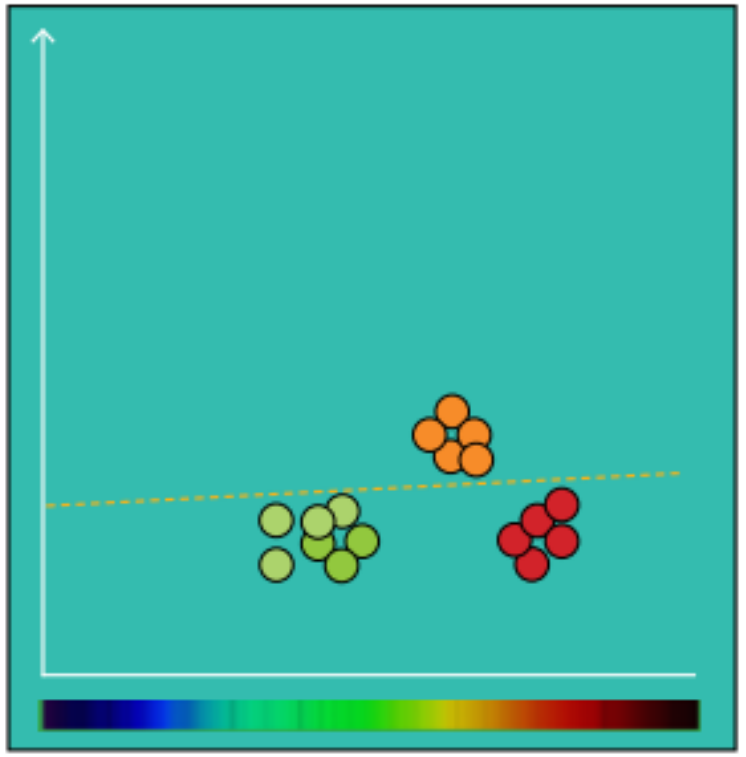

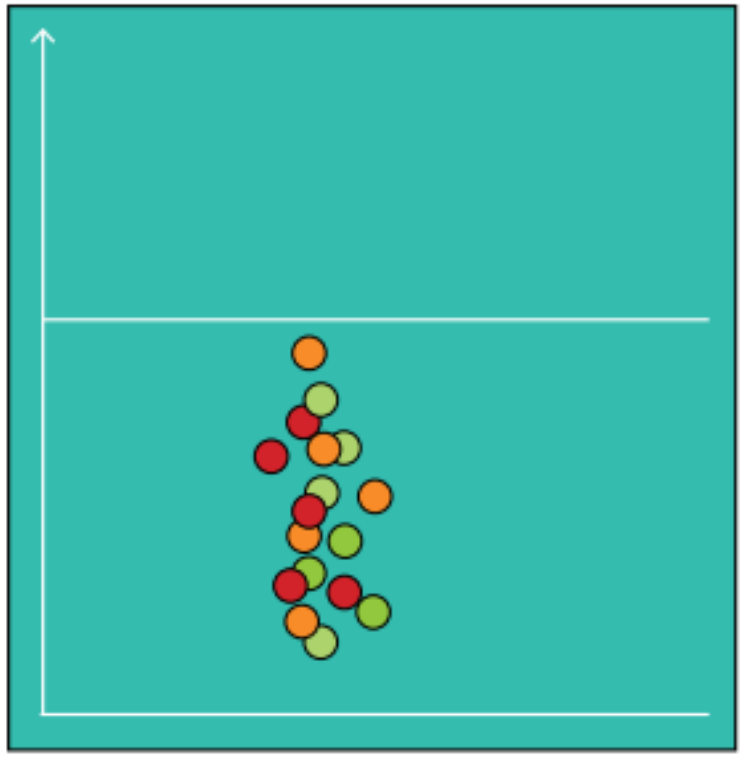

Figure 3.

Dividing apples and oranges and others based on the feature of color results in a meaningful output.[19]

Dividing apples and oranges based on the feature of size makes distinguishing them much harder.[20]

Future of Privacy (2019). *The Privacy Expert's Guide to AI and Machine Learning*. URL: https://fpf.org/wp-content/uploads/2018/10/FPF_Artificial-Intelligence_Digital.pdf

Een empirisch model

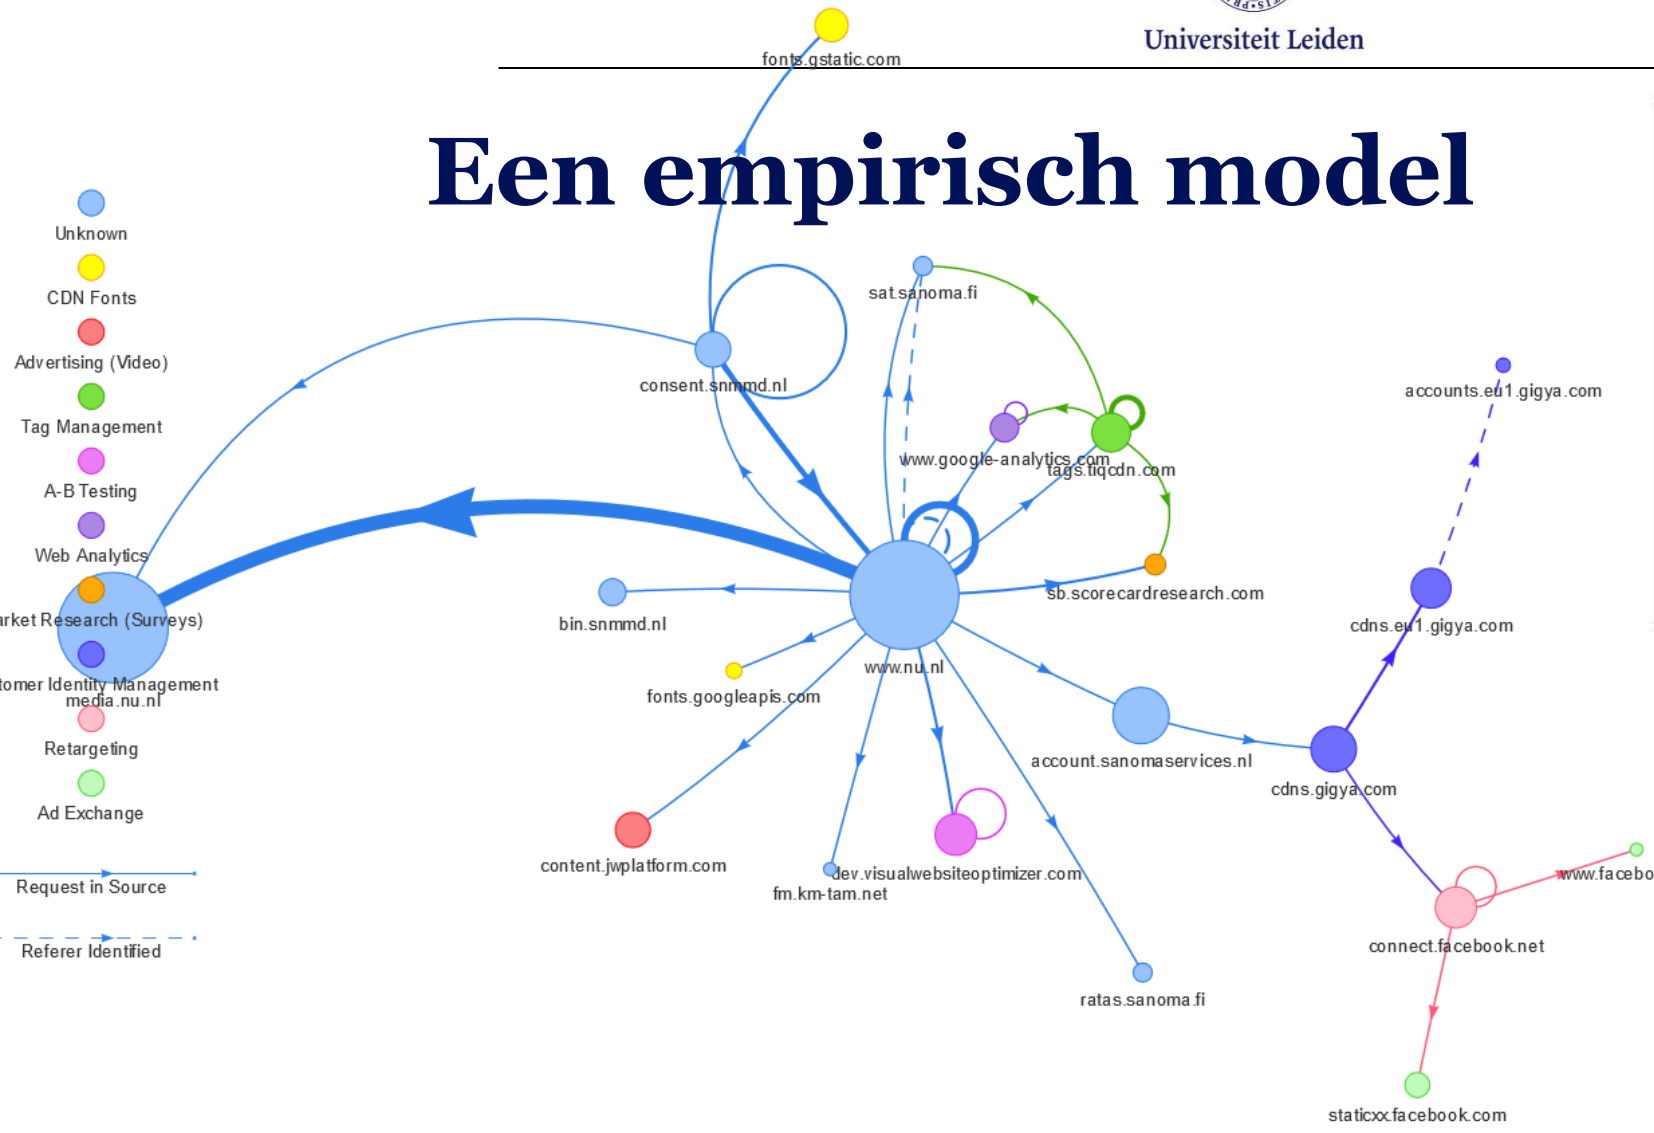

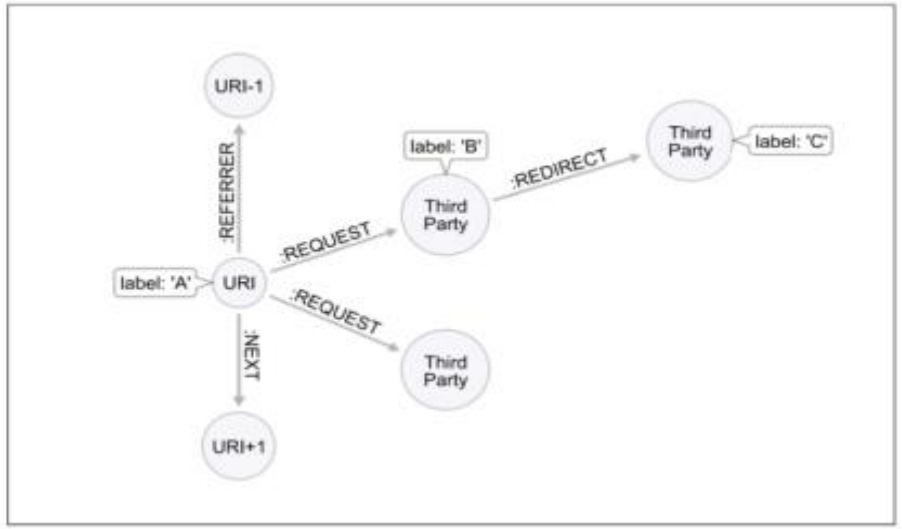

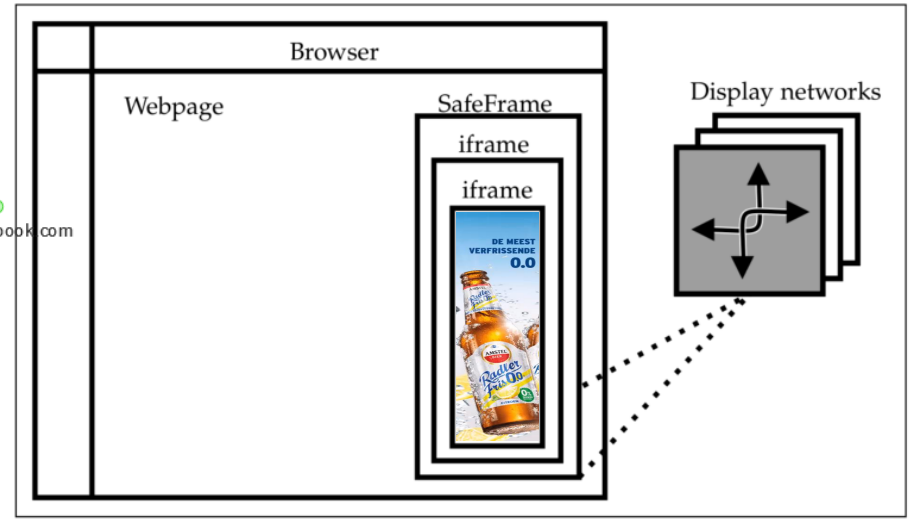

Tracking cookies in de waardeketen

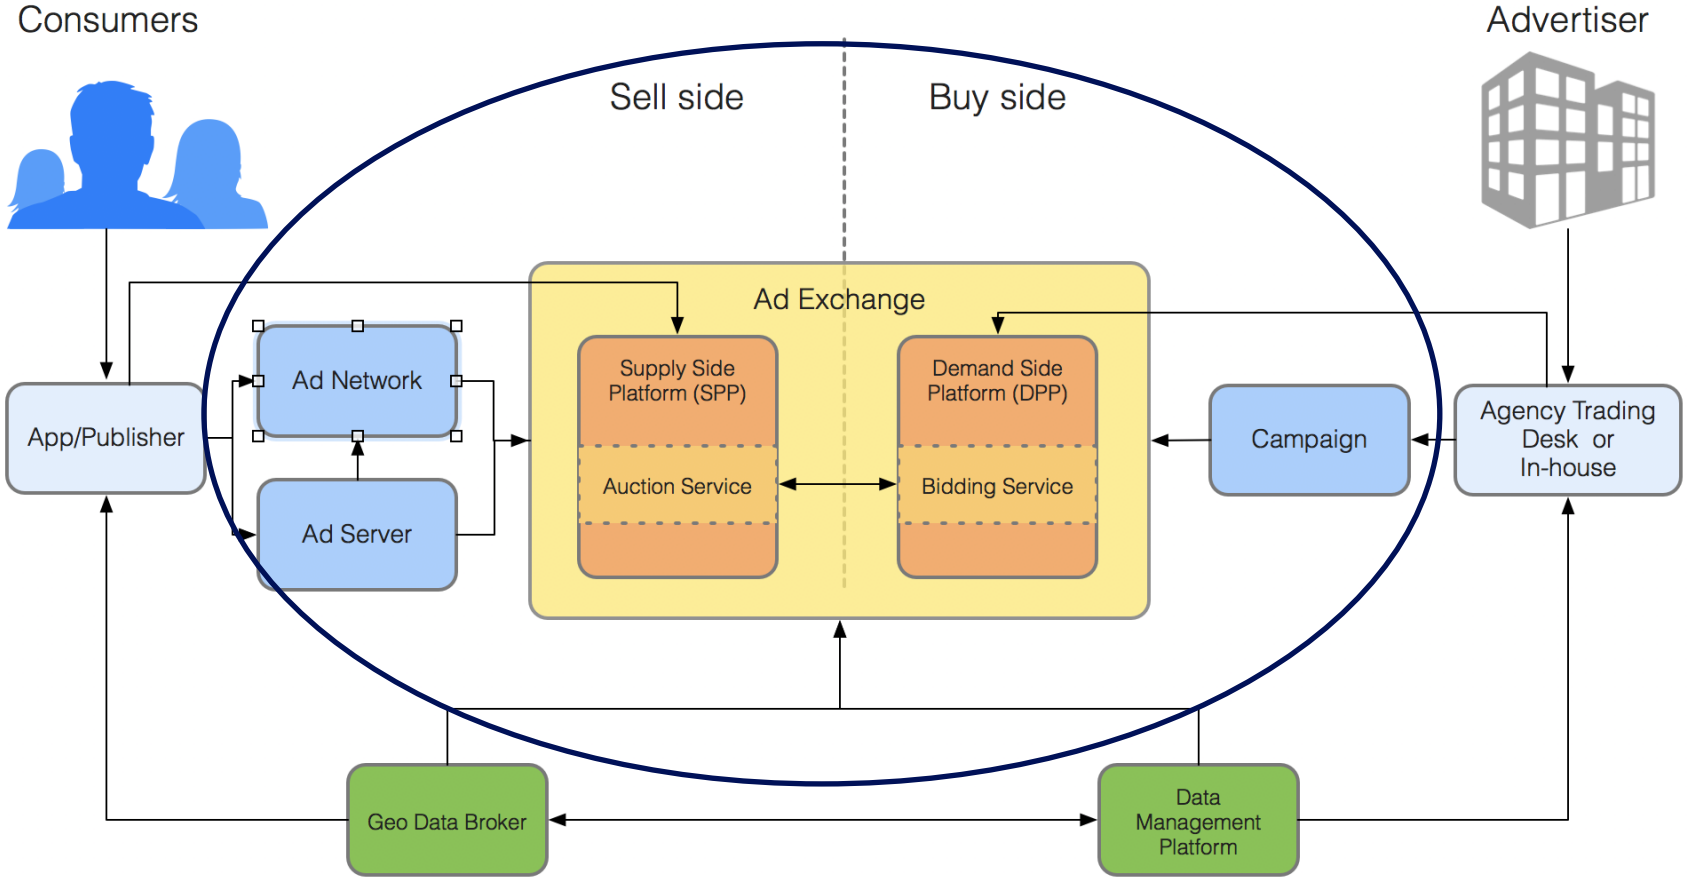

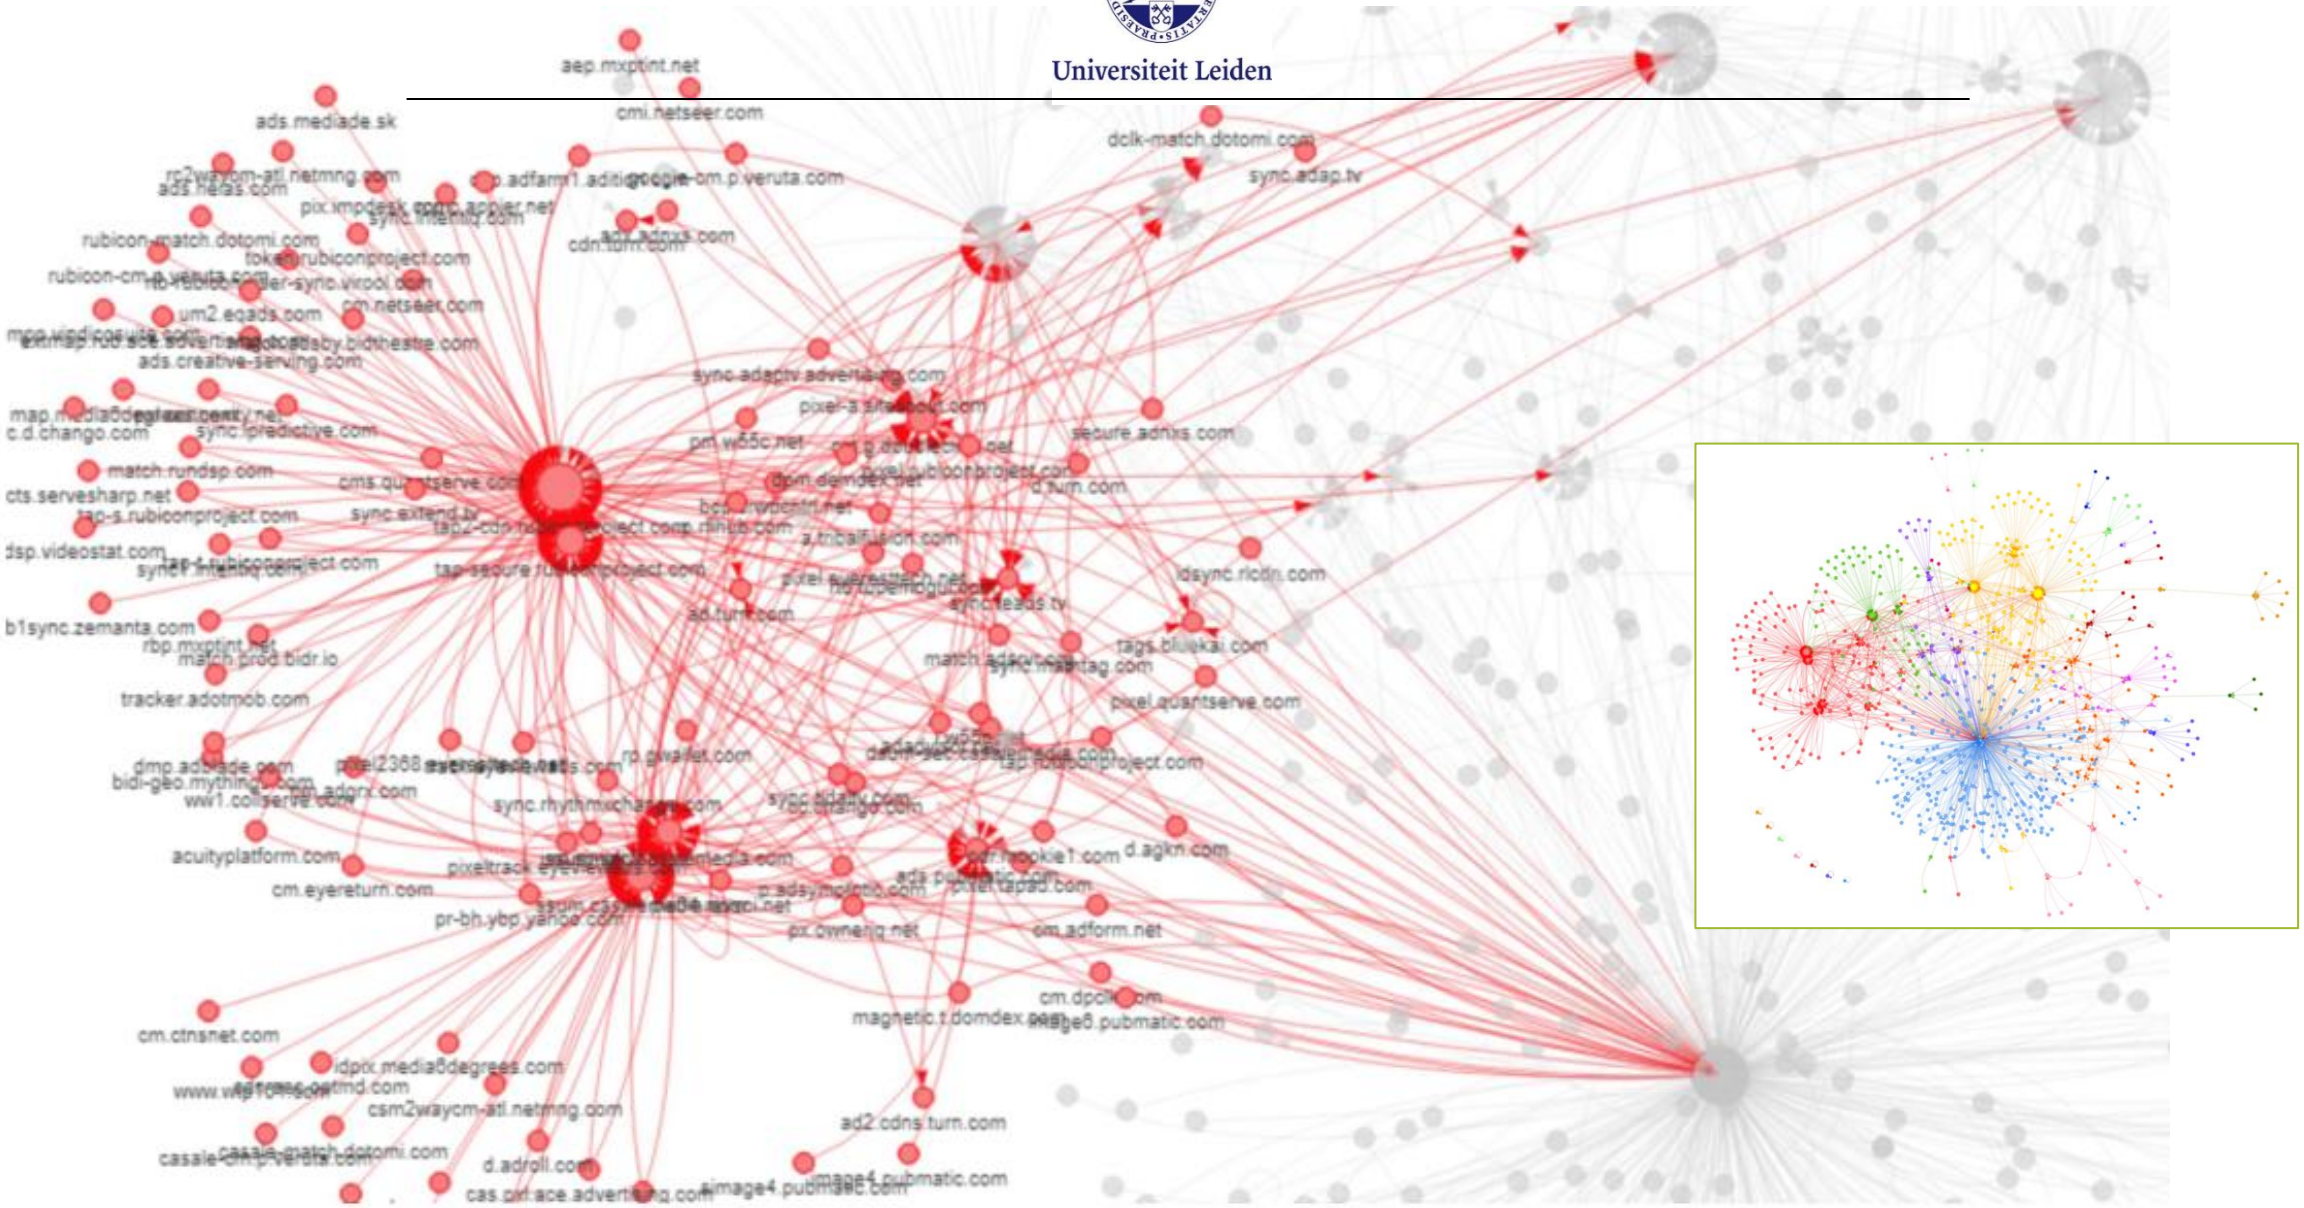
aep.mxptint.net
cmi.netseer.com
ads.mediade.sk
dclk-match.dotomi.com
sync.adap.tv
rubicon-match.dotomi.com
token.rubiconproject.com
um2.eqads.com
cm.netseer.com
ads.creative-serving.com
sync.adaptv.advertising.com
secure.adnxs.com
c.d.chango.com
sync.ipredictive.com
match.rundsp.com
cts.servesharp.net
sync.extend.tv
dsp.videostat.com
idsync.rlcdn.com
b1sync.zemanta.com
tracker.adotmob.com
pixel.quantserve.com
acuityplatform.com
cm.eyereturn.com
d.agkn.com
cm.adform.net
cm.ctnsnet.com
csm2waycm-atl.netmng.com
ad2.cdns.turn.com
d.adroll.com
image4.pubmatic.com

Universiteit Leiden

Wat zijn toepassingen gerelateerd aan de juridische en beleidsmatige praktijk?

- Gericht adverteren vereist toestemming voor cookies
- Contextueel adverteren zonder toestemming
- Het R-getal (COVID-19)

Adverteren zonder toestemming [1]

https://www.npostart.nl/

Adverteren zonder toestemming [2]

- STER maakt gebruik van een database met ondertitelingen.

Rick Hoving (STER) (2020). Adverteren zonder cookies. In: *bvA webinar Cookieless*.

Adverteren zonder toestemming [3]

- STER maakt gebruik van een database met ondertitelingen.
- Vervolgens worden de woorden in een aflevering geteld om een weging aan te brengen in de data.

KONING	5/10 = 0,50
BETREURT	7/258 = 0,02
RESPECTEERT	8/398=0,02
BREXIT	2/16=0,16
TIJDENS	18/981=0,02
SPEECH	12/451=0,03
STAATSBEZOEK	18/21=0,85

Rick Hoving (STER) (2020). Adverteren zonder cookies. In: *bvA webinar Cookieless*.

Adverteren zonder toestemming [4]

- STER maakt gebruik van een database met ondertitelingen per aflevering.
- Vervolgens worden de woorden in een aflevering geteld om een weging aan te brengen in de data.
- Daarna worden de kernwoorden omgezet naar een graaf (WORD2VEC).
- Met woordvectoren worden kern-woorden in de ondertiteling omgezet naar interessekanalen (23 stuks).

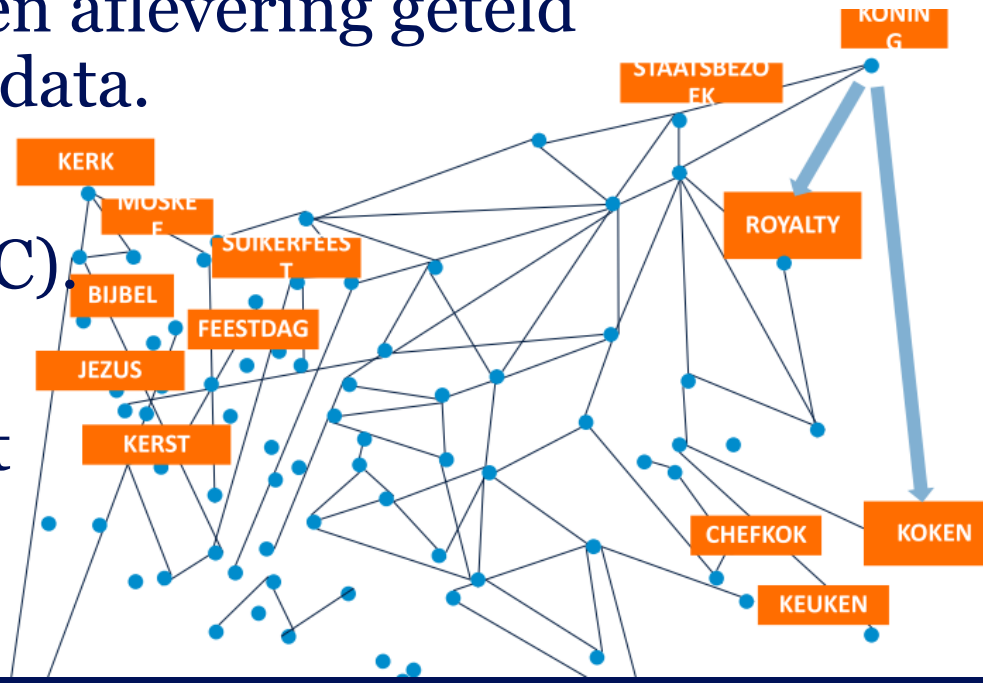

Rick Hoving (STER) (2020). Adverteren zonder cookies. In: *bvA webinar Cookieless*.

Interessekanalen in de waardeketen

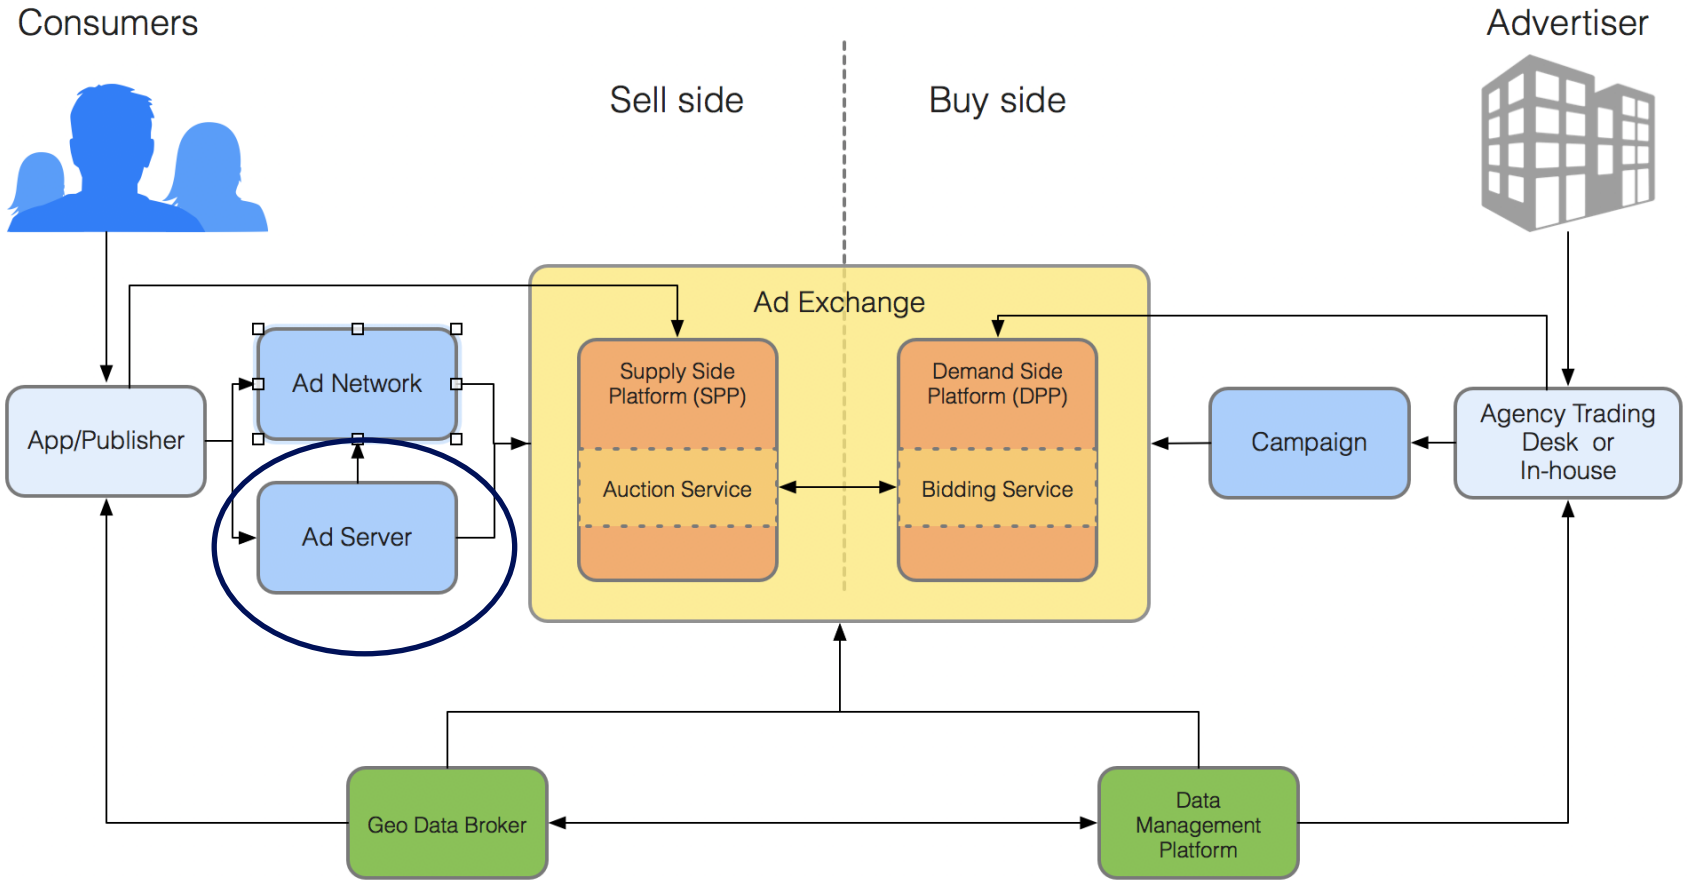

Adverteren zonder toestemming [4]

- Om biedingen voor een advertentieruimte te kunnen koppelen aan de webpagina zijn twee random nummer nodig, het *bid_id* en het *external_user_id*, bijvoorbeeld:
  - bid_id=1603530602_1A936AA1037B48415BC393E61CA5B9C1_70_00563807_41&
  - external_user_id=1603530602-56258070&
- Beide nummers worden allemaal slechts één keer random gegenereerd en vervolgens verwijderd.
- De nummers worden niet als tracking cookies geplaatst.

Tom van Bentheim (STER) (16 oktober 2020). RE: Onderzoek Ster [Persoonlijke Correspondentie].

Universiteit Leiden

Wat zijn toepassingen gerelateerd aan de juridische en beleidsmatige praktijk?

- Gericht adverteren vereist toestemming voor cookies
- Contextueel adverteren zonder toestemming
- Het R-getal (COVID-19)

Rijksinstituut voor Volksgezondheid en Milieu
Ministerie van Volksgezondheid, Welzijn en Sport

RIVM *De zorg voor morgen* begint vandaag

Onderwerpen Over RIVM Publicaties Internationaal Contact Zoeken

Home › COVID 19 › Actuele informatie over COVID 19 › Wekelijkse update epidemiologische situatie COVID 19 in Nederland

Wekelijkse update epidemiologische situatie COVID-19 in Nederland

Hier kun je de epidemiologische situatie van COVID-19 in Nederland downloaden. Deze pagina wordt elke dinsdag bijgewerkt met nieuwe informatie.

→ Epidemiologische situatie COVID-19 in Nederland (8 juni 2021)

Direct naar

→ Actuele informatie over het nieuwe coronavirus (COVID-19)

https://www.rivm.nl/coronavirus-covid-19/actueel/wekelijkse-update-epidemiologische-situatie-covid-19-in-nederland

Het reproductiegetal R geeft aan hoe snel het virus zich verspreidt. Het getal staat voor het gemiddeld aantal mensen dat iemand met COVID-19 besmet. Een reproductiegetal van 1 betekent dat 100 mensen, 100 andere mensen besmetten. Het virus blijft zich verspreiden. Een R van 1,39 bijvoorbeeld betekent dat 100 mensen 139 andere mensen besmetten, het virus verspreidt zich snel. Als R lang onder de 1 blijft dooft het virus uit. R is dus een belangrijk getal om te zien hoe snel het virus zich in Nederland verspreidt. En hoe intensief maatregelen moeten zijn om verdere verspreiding te stoppen.

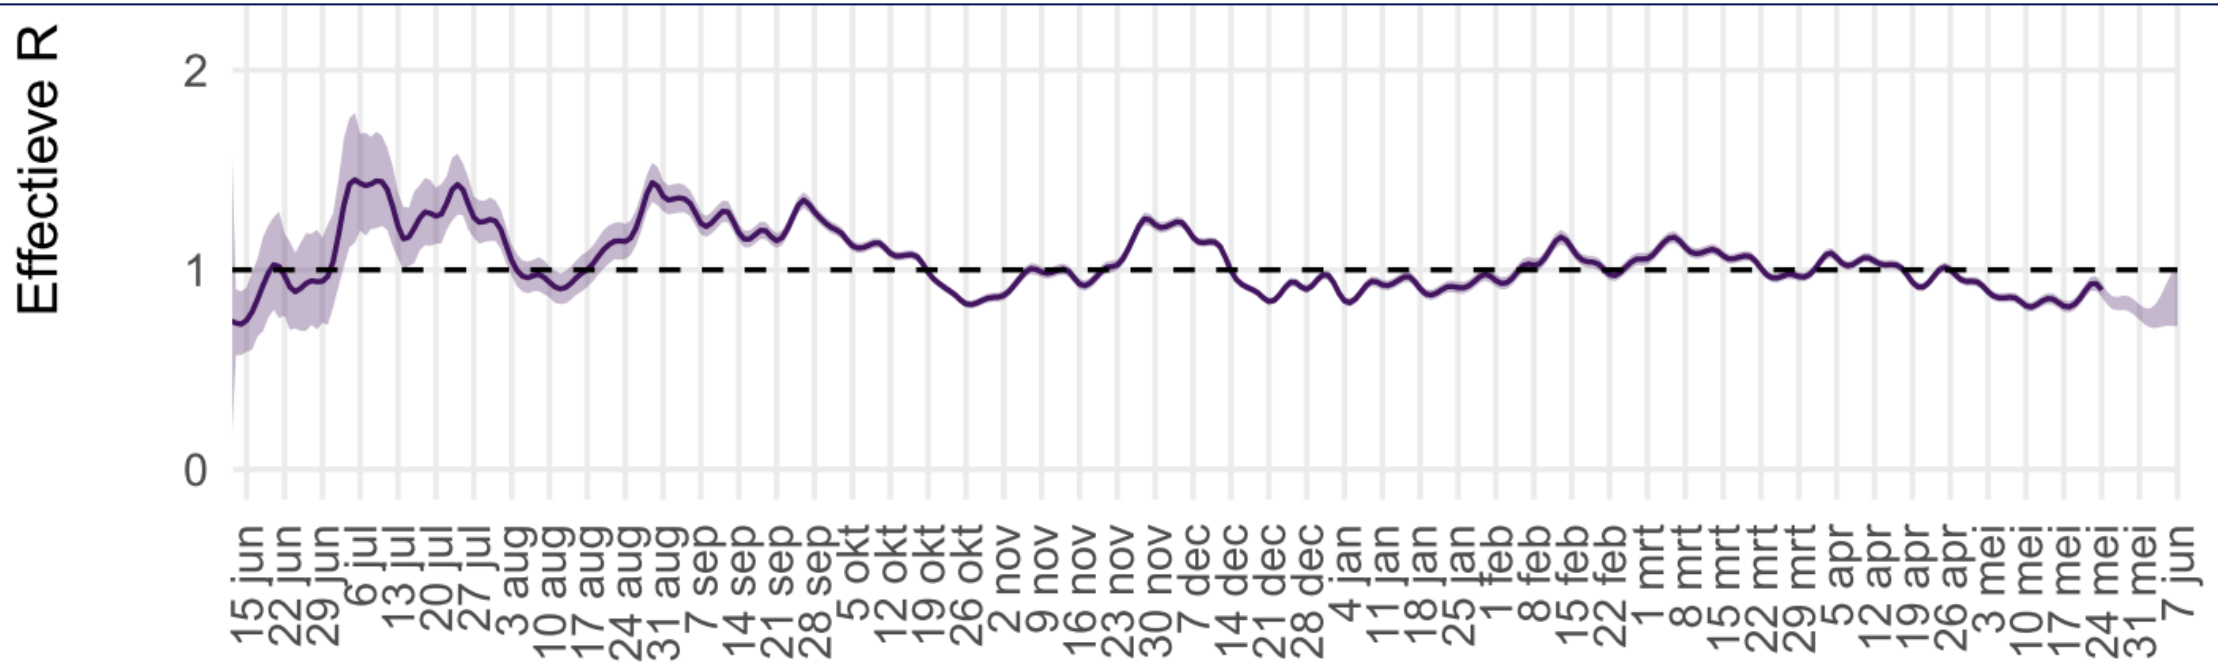

Figuur 28: Het effectieve reproductiegetal R voor Nederland.

https://www.rivm.nl/sites/default/files/2021-06/COVID-19_WebSite_rapport_wekelijks_20210608_1316_final.pdf

De gegevens die worden gebruikt voor de berekening van R:

- Gegevens van de Nationale Intensive Care Evaluatie (NICE). Dit zijn cijfers over het aantal ziekenhuisopnames
- in Nederland en het aantal opnames op de intensive care.
- Gegevens van de GGD'en. Zij zetten informatie over nieuwe patiënten met COVID-19 in het systeem OSIRIS information system . Daarbij geven zij het aantal nieuwe patiënten aan, wat hun de eerste ziektedag is, de mogelijke besmettingsbron en het aantal mensen dat in het ziekenhuis werd opgenomen. Alle gegevens komen via OSIRIS bij het RIVM. Het RIVM beheert dit systeem en werkt aan het toegankelijk maken van deze gegevens . De gegevens die we openbaar maken, moeten voldoen aan de wetgeving voor privacy, de Algemene Verordening Persoonsgegevens (AVG).

Om het reproductiegetal R te berekenen, moet je weten hoe het aantal gevallen van COVID-19 toeneemt in de tijd. Hiervoor gebruiken we het aantal gemelde COVID-19 gevallen per dag in Nederland. Ook moet je weten wat de tijd is tussen de eerste ziektedag van een COVID-19 patiënt en de eerste ziektedag van zijn of haar besmetter. Op basis van de gegevens uit Nederland weten we dat de gemiddelde tijd 4 dagen is. We gebruiken een bestaande methode om het reproductiegetal te schatten.

https://www.rivm.nl/coronavirus-covid-19/rekenmodellen#hoe-bereken-je-de-r-454461-more

De gegevens die worden gebruikt voor de berekening van R:

- Gegevens van de Nationale Intensive Care Evaluatie (NICE). Dit zijn cijfers over het aantal ziekenhuisopnames

In the classical SIR model of disease transmission, the attack rate (AR : the percentage of the population eventually infected) is linked to the basic reproduction number [9], by $R_0 = -\frac{\log\left(\frac{1-AR}{S_0}\right)}{AR-(1-S_0)}$ where S_0 is the initial percentage of susceptible population. The required assumptions are homogeneous mixing, closed population, and no intervention during the outbreak.

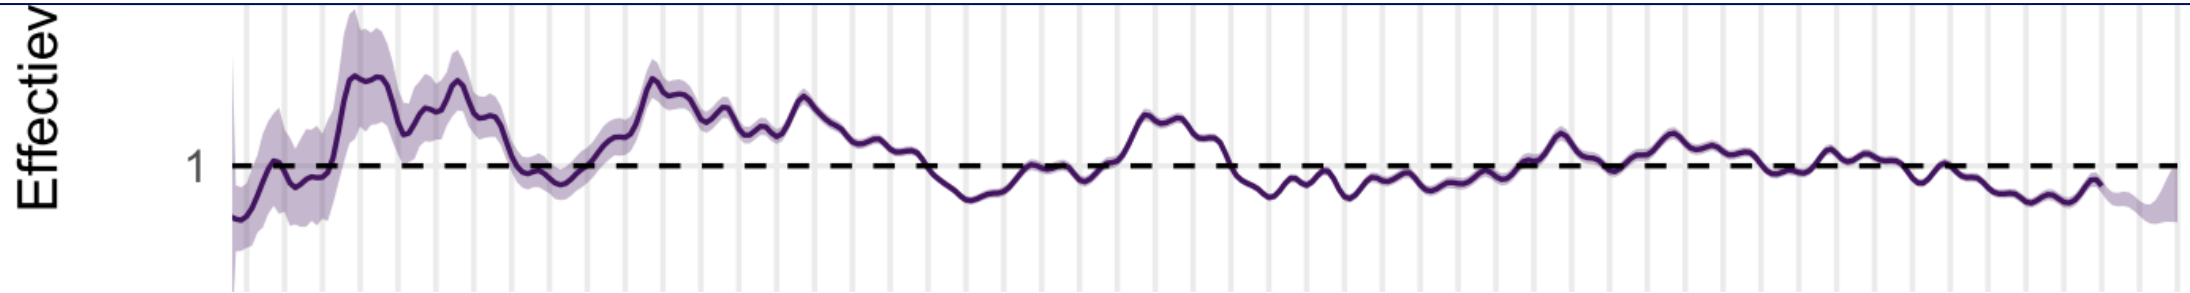

Om het reproductiegetal R te berekenen, moet je weten hoe het aantal gevallen van COVID-19 toeneemt in de tijd. Hiervoor gebruiken we het aantal gemelde COVID-19 gevallen per dag in Nederland. Ook moet je weten wat de tijd is tussen de eerste ziektedag van een COVID-19 patiënt en de eerste ziektedag van zijn of haar besmetter. Op basis van de gegevens uit Nederland weten we dat de gemiddelde tijd 4 dagen is. We gebruiken een bestaande methode om het reproductiegetal te schatten.

https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3582628/

De gegevens die worden gebruikt voor de berekening van R:

- Gegevens van de Nationale Intensive Care Evaluatie (NICE). Dit zijn cijfers over het aantal ziekenhuisopnames

In the classical SIR model of disease transmission, the attack rate (AR : the percentage of the population eventually infected) is linked to the basic reproduction number [9], by $R_0 = -\frac{\log\left(\frac{1-AR}{S_0}\right)}{AR-(1-S_0)}$ where S_0 is the initial percentage of susceptible population. The required assumptions are homogeneous mixing, closed population, and no intervention during the outbreak

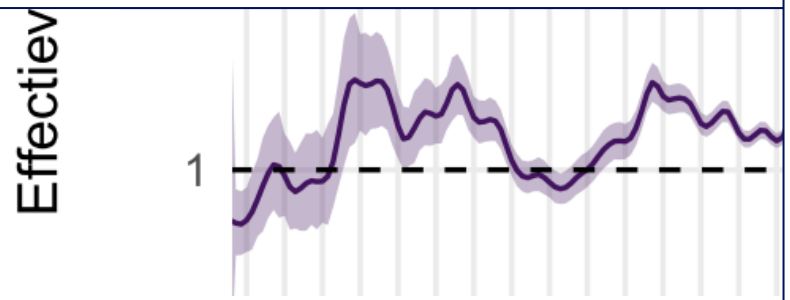

Om het reproductiegetal R te berekenen, moe
Hiervoor gebruiken we het aantal gemelde CO
tussen de eerste ziektedag van een COVID-19
de gegevens uit Nederland weten we dat de g
reproductiegetal te schatten.

```
@examples
## load data on pandemic flu in a school in 2009
data("Flu2009")

## estimate the reproduction number (method "non_parametric_si")
## when not specifying t_start and t_end in config, they are set to estimate
## the reproduction number on sliding weekly windows
res <- estimate_R(incid = Flu2009$incidence,
                  method = "non_parametric_si",
                  config = make_config(list(si_distr = Flu2009$si_distr)))
plot(res)

## the second plot produced shows, at each each day,
## the estimate of the reproduction number over the 7-day window
## finishing on that day.
```

https://en.wikipedia.org/wiki/Nonparametric_statistics

De gegevens die worden gebruikt voor de berekening van R:

er het aantal ziekenhuisopnames

Non-parametric models [edit]

Non-parametric models differ from parametric models in that the model structure is not specified *a priori* but is instead determined from data. The term *non-parametric* is not meant to imply that such models completely lack parameters but that the number and nature of the parameters are flexible and not fixed in advance.

- A histogram is a simple nonparametric estimate of a probability distribution.
- Kernel density estimation provides better estimates of the density than histograms.
- Nonparametric regression and semiparametric regression methods have been developed based on kernels, splines, and wavelets.
- Data envelopment analysis provides efficiency coefficients similar to those obtained by multivariate analysis without any distributional assumption.
- KNNs classify the unseen instance based on the K points in the training set which are nearest to it.
- A support vector machine (with a Gaussian kernel) is a nonparametric large-margin classifier.
- The method of moments with polynomial probability distributions.

: the percentage of the population

$R_0 = -\frac{\log\left(\frac{1-AR}{S_0}\right)}{AR-(1-S_0)}$ where S_0 is the

are homogeneous mixing, closed

a school in 2009

Om het reproductiegetal R te berekenen, moe

Hiervoor gebruiken we het aantal gemelde CO

tussen de eerste ziektedag van een COVID-19

de gegevens uit Nederland weten we dat de g

reproductiegetal te schatten.

```
## estimate the reproduction number (method "non_parametric_si")
## when not specifying t_start and t_end in config, they are set to estimate
## the reproduction number on sliding weekly windows
res <- estimate_R(incid = Flu2009$incidence,
                  method = "non_parametric_si",
                  config = make_config(list(si_distr = Flu2009$si_distr)))
plot(res)

## the second plot produced shows, at each each day,
## the estimate of the reproduction number over the 7-day window
## finishing on that day.
```

https://en.wikipedia.org/wiki/Nonparametric_statistics

Conclusie

- De aanpak met support-vector machines (SVMs) moet je oefenen!

Dank voor uw aandacht

Contact: rvaneijk@fpf.org